



東北大學 秦皇島分校
Northeastern University at Qinhuangdao

畢業論文

基於強化學習的無人機輔助計算卸載策略優化研究

院 別	悉尼智能科技学院
專業名稱	計算機科學與技術
班級學號	2202-202219016
學生姓名	靳博元
指導教師	袁曉銘

2026 年 5 月

郑重声明

本人呈交的学位论文，是在导师的指导下，独立进行研究工作所取得的成果，所有数据、图片资料真实可靠。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确的方式标明。本学位论文的知识产权归属于培养单位。

本人签名：靳博元 日期：2026年5月22日

基于强化学习的无人机辅助计算卸载策略优化研究

摘 要

针对在无人机辅助移动边缘计算系统中，能量受限、信道动态变化以及任务随机到达等问题，本文研究了计算卸载与无人机飞行路径的联合优化方法。本论文构建了单无人机多用户边缘计算系统模型。无人机搭载边缘服务器，可以为地面用户提供计算服务。用户任务既可以在本地执行，也可以选择部分卸载到无人机中处理。空地通信过程采用了概率视距链路模型。

系统建模基础上，本文将联合优化问题转化为马尔可夫决策过程。状态空间包括无人机水平位置、剩余电量以及当前用户任务数据量等信息。动作空间包含无人机飞行位置增量和任务卸载比例。奖励函数由任务处理时延与无人机能耗构成，用来反映系统整体开销。

结合连续动作空间特点，本文设计了一种基于深度确定性策略梯度的联合优化算法。算法利用 Actor 网络输出动作决策，Critic 网络评估当前状态动作价值，并引入经验回放与目标网络机制以提高训练稳定性。智能体通过与环境不断交互，逐步学习较优的卸载与轨迹控制策略。

实验部分搭建了对应的仿真环境，并设置了本地计算、随机卸载、贪婪路径以及固定无人机位置等方法作为对比。结果表明，所采用的深度确定性策略梯度的联合优化算法能够较稳定地完成训练，在降低任务时延和系统能耗等方面展现了较好的效果。

关键词：边缘计算；计算卸载；强化学习

Research on Optimization of Unmanned Aerial Vehicle-Assisted Computing Offloading Strategies Based on Reinforcement Learning

Abstract

In the context of the unmanned aerial vehicle (UAV)-assisted mobile edge computing system, where there are issues such as energy constraints, dynamic channel changes, and randomly arriving tasks, this thesis investigates a joint optimization method for computing offloading and UAV flight paths. The thesis constructs a single-UAV multi-user edge computing system model. The UAV is equipped with an edge server to provide computing services to ground users. User tasks can either be executed locally or partially offloaded to the UAV for processing. The air-ground communication process adopts a probabilistic line-of-sight link model.

Based on system modeling, this thesis transforms the joint optimization problem into a Markov decision process. The state space includes information such as the horizontal position of the UAV, remaining battery power, and the current user task data volume. The action space includes the increment of the UAV's flight position and the proportion of task offloading. The reward function is composed of task processing delay and UAV energy consumption, reflecting the overall system overhead.

Taking into account the characteristics of the continuous action space, this thesis designs a joint optimization algorithm based on deep deterministic policy gradient. This algorithm uses the Actor network to output action decisions, the Critic network to evaluate the current state-action value, and introduces experience replay and target network mechanisms to improve training stability. The agent learns better offloading and trajectory control strategies through continuous interaction with the environment.

The experimental part sets up the corresponding simulation environment and designs methods such as local computing, random offloading, greedy path, and fixed UAV position as comparisons. The results show that the deep deterministic policy gradient-based joint optimization algorithm can complete training stably, and the UAV trajectory will adjust according to the user distribution changes. It achieves good effects in reducing task delay and system energy consumption.

Key words: Edge computing; Computing offloading; Reinforcement learning

目 录

1 绪 论	1
1.1 引言	1
1.2 研究背景	2
1.2.1 无人机辅助边缘计算的兴起	2
1.2.2 计算卸载策略的挑战	3
1.2.3 强化学习的适用性	4
1.3 国内外研究现状	4
1.3.1 无人机辅助 MEC 系统研究	4
1.3.2 计算卸载与资源分配策略研究	5
1.3.3 强化学习在无人机辅助 MEC 中的应用	6
1.3.4 研究现状总结与问题提炼	6
1.4 研究意义与内容	6
1.4.1 理论意义	7
1.4.2 实际意义	8
1.4.3 主要研究内容	8
1.5 论文组织结构	9
2 相关技术综述	11
2.1 边缘计算	11
2.1.1 移动边缘计算概述	11
2.1.2 无人机辅助边缘计算	14
2.2 强化学习基础	16
2.2.1 马尔可夫决策过程	16
2.2.2 Q 学习与深度 Q 网络	18
2.2.3 Actor-Critic 与深度确定性策略梯度	20
2.2.4 其他先进算法简介	21
2.3 本章小结	21

3 系统模型与基于 DDPG 的联合优化算法设计	23
3.1 系统模型	23
3.1.1 系统架构	23
3.1.2 通信模型	24
3.1.3 计算模型	25
3.1.4 无人机能耗模型	26
3.2 问题建模与 MDP 形式化	27
3.2.1 状态空间	28
3.2.2 动作空间	28
3.2.3 奖励函数	29
3.2.4 优化目标	29
3.3 基于 DDPG 的联合优化算法设计	30
3.3.1 DDPG 算法原理	30
3.3.2 网络结构设计	32
3.3.3 探索噪声	32
3.3.4 超参数设置	33
3.3.5 算法训练流程	33
3.4 本章小结	35
4 仿真实验与结果分析	37
4.1 仿真环境设置	37
4.1.1 开发工具与框架	37
4.1.2 仿真参数设置	37
4.1.3 仿真流程	38
4.2 对比算法介绍	38
4.3 实验结果分析	39
4.3.1 训练收敛性分析	39
4.3.2 性能对比分析	40
4.3.3 参数影响分析	43
4.4 本章小结	45

结 论	47
致 谢	49
参考文献	50
附 录	53

1 绪 论

1.1 引言

近几年，5G、物联网还有人工智能相关技术发展得很快，智能终端设备的数量也越来越多。智能手表、家用传感器、车载设备这些终端，在日常运行过程中都会不断产生数据和计算任务。随着应用场景越来越复杂，系统对计算能力的要求也越来越高。除了计算量增加之外，很多场景对时延和能耗也比较敏感。比如人脸识别、AR 以及自动驾驶等应用，通常都要求系统能够快速完成任务处理。如果响应时间太长，用户体验会明显变差。有些实时性要求高的场景，甚至还可能出现安全问题。

传统云计算虽然计算能力比较强，但很多数据都需要传输到远端云服务器之后再进行处理。数据在网络里来回传输，会带来额外时延，同时还会增加核心网络的通信压力。对于一些低时延任务来说，这种处理方式已经不太适合。也正因为这样，移动边缘计算（Mobile Edge Computing, MEC）开始逐渐受到关注。它的思路其实比较直接，就是把部分计算资源放到离用户更近的位置，比如基站附近或者接入点附近。这样用户设备产生任务后，可以直接把数据发送到边缘节点，不需要全部传输到远端云中心。数据传输距离变短之后，任务处理速度通常会更快一些，网络压力也会减轻。

传统地基 MEC 系统大多依赖固定基站或者路边单元提供服务，但这类设备的位置基本固定，覆盖范围也有限。在一些特殊场景下，比如自然灾害、偏远地区通信或者临时大型活动，地面基础设施有时无法正常工作，或者很难应对短时间内的大量业务请求。相比之下，无人机（Unmanned Aerial Vehicle, UAV）的灵活性会更高一些。无人机可以快速飞到目标区域，而且空地之间通常能够形成较好的视距（Line-of-sight, LoS）链路，因此通信条件相对稳定。基于这个特点，将边缘服务器搭载到无人机上，就形成了无人机辅助 MEC 系统。无人机能够根据用户位置变化不断调整飞行位置，为地面用户提供更加灵活的边缘计算服务。对于传统网络覆盖不足的区域，这种方式会更加方便。

在无人机辅助 MEC 系统中，飞行路径和任务卸载策略之间其实是互相影响的，这也是整个问题里比较难处理的一部分。如果无人机离用户比较远，通信速率会下降，任务传输时间也会增加；但如果无人机频繁移动，又会消耗更多飞行能量。与此同时，系统还需要决定任务是在本地执行，还是卸载到无人机处理，以及具体卸载多少。飞行位

置、链路状态、任务负载之间会互相影响，并不是单独优化某一个部分就能解决问题。除此之外，系统还会受到无线信道变化、任务随机到达以及无人机剩余电量等因素影响，因此整个环境具有较强动态性。传统优化方法通常依赖较理想化的数学模型，在动态环境下求解难度较高，而且实时调整能力也有限。相比之下，强化学习特别是深度强化学习（Deep Reinforcement Learning, DRL），能够通过不断与环境交互来学习策略，因此更适合处理这种连续动态决策问题。通过将系统建模为马尔可夫决策过程（Markov Decision Process, MDP），智能体可以逐步学习无人机轨迹控制与任务卸载之间的关系，并在训练过程中不断调整策略。

整体来看，基于深度强化学习的无人机辅助 MEC 联合优化方法，可以为动态边缘计算环境下的资源调度问题提供一定参考，也能够为后续相关研究提供一些思路。

1.2 研究背景

1.2.1 无人机辅助边缘计算的兴起

移动边缘计算的提出，在一定程度上缓解了终端设备计算能力不足以及传统云计算时延较高的问题。不过，MEC 系统的实际效果和边缘节点的部署位置关系很大。如果边缘服务器部署不合理，即使计算能力足够，也很难保证服务质量。在一些城市热点区域，通过增加基站数量、部署 MEC 服务器，确实能够改善部分覆盖问题，但在一些特殊场景下，传统 MEC 架构还是存在比较明显的限制。

比如在地震、洪水、火灾等灾害场景中，地面通信基础设施可能会受到严重破坏。这个时候，救援人员往往需要在短时间内完成通信、定位以及数据处理等任务，但原有网络已经无法正常工作。尤其是在灾后初期阶段，通信中断会直接影响救援效率，因此需要一种能够快速部署的临时通信和计算网络。除了灾害场景之外，山区、沙漠、海洋等偏远地区也存在类似问题。这些区域本身人口较少，建设固定基站的成本比较高，后期维护也比较困难，因此很多地方网络覆盖并不完善。一些依赖网络的应用，比如车联网、环境监测等，在这些区域很难稳定运行。还有一种情况，就是临时高密度用户场景。像体育赛事、演唱会、大型集会这类活动，在短时间内会聚集大量用户，周边基站很容易出现拥塞，网络质量下降比较明显。很多时候并不是系统完全无法使用，而是时延和数据传输速度会变得很差。

在这些场景下，无人机相比传统地面设备会更加灵活。无人机能够在较短时间内飞

到目标区域上空，快速建立通信链路，这一点在应急场景中比较实用。另外，由于无人机处于空中，和地面用户之间通常能够形成较好的视距通信链路，因此路径损耗相对较小。相比复杂城市环境中的地面非视距传输，空地通信往往会更加稳定一些，数据传输速率也更容易得到保障。近年来，随着电池技术以及轻量化芯片的发展，中小型无人机的续航能力和计算能力都有了一定提高。虽然还无法和大型服务器相比，但完成部分边缘计算任务已经没有太大问题。也正因为这样，将无人机作为空中 MEC 节点，构建空地协同的边缘计算网络，逐渐成为当前比较受关注的研究方向。

1.2.2 计算卸载策略的挑战

计算卸载是 MEC 系统中的一个核心问题，系统性能很大程度上会受到卸载策略影响。在无人机辅助 MEC 场景下，这个问题会比传统地面 MEC 更加复杂。因为无人机本身是移动的，很多因素之间会互相影响，并不是单独优化某一个部分就可以解决。

一个比较明显的问题，是飞行路径和卸载决策之间存在耦合关系。无人机飞到不同位置后，空地链路质量会发生变化，通信速率和传输能耗也会跟着变化。与此同时，无人机的位置还会影响当前能够服务哪些用户。如果无人机距离用户较远，任务上传时间会明显增加；但如果频繁调整飞行位置，又会带来额外能耗。另一方面，任务卸载策略本身也会影响无人机状态。比如卸载任务越多，无人机计算负载越高，悬停时间也会更长，这又会进一步增加能耗。所以路径规划和任务卸载之间并不是独立关系，而是互相影响的。很多情况下，如果只优化其中一个部分，整体效果并不会太理想。

除了决策之间的关联问题，系统环境本身也具有较强动态性。用户任务什么时候到达、任务数据量大小、需要多少计算资源，这些通常都不是固定的。无线信道环境也会受到天气、障碍物以及用户移动等因素影响，因此链路状态会不断变化。另外，无人机电量会随着飞行、通信和计算持续消耗，而电量一旦不足，又会影响后续任务处理能力。也就是说，整个系统状态是在不断变化的，系统需要根据当前环境实时调整策略，而不是提前给出一个固定方案。

资源受限问题也是无人机辅助 MEC 中比较现实的一部分。大多数小型无人机电池容量有限，续航能力本身就不算特别强。无人机飞行需要耗电，悬停需要耗电，通信和任务计算同样也会消耗能量。如果能量消耗过快，无人机可能无法继续提供服务。因此，在有限电量条件下，如何尽量减少任务处理时延，同时保证更多任务能够完成，是系统

设计时必须考虑的问题。这其实也是很多无人机相关研究里经常出现的一个矛盾。

另外，这类问题的动作空间通常是连续的。实际系统中，无人机飞行方向、飞行速度以及任务卸载比例都不是固定离散值，而是连续变化的。例如卸载比例可能是 0.3，也可能是 0.75，而不仅仅只有全部卸载或者全部本地计算两种情况。传统基于值函数的方法，例如 DQN，更适合处理离散动作空间，对于这种连续控制问题并不太适用。

1.2.3 强化学习的适用性

在这种情况下，强化学习方法会更适合一些。尤其是深度强化学习，能够通过与环境不断交互来学习策略，而不需要提前建立特别精确的数学模型。相比传统优化方法，它对动态环境的适应能力会更强一些。对于无人机辅助 MEC 系统，可以将整个问题建模为马尔可夫决策过程。无人机作为智能体，在每个时刻观察系统当前状态，比如自身位置、剩余电量、用户任务情况以及信道状态等，然后根据当前策略输出动作，包括飞行方向、卸载比例以及资源分配等。环境接收到动作之后，会转移到新的状态，同时返回对应奖励值。智能体通过不断训练，逐渐学习更加合适的决策策略。

深度确定性策略梯度（Deep Deterministic Policy Gradient, DDPG）算法比较适合处理这类问题。DDPG 是 Actor-Critic 结构，Actor 网络的作用是输出连续动作，Critic 网络评估当前动作的效果。为提高训练稳定性，DDPG 中引入了经验回放和目标网络机制，从而减少训练过程中的数据相关性问题。由于无人机辅助 MEC 中的很多控制变量本身就是连续的，使用 DDPG 进行联合优化，比传统离散动作强化学习方法会更适合。

1.3 国内外研究现状

近几年，移动边缘计算和无人机相关研究发展得比较快，两者结合之后，也逐渐成为当前边缘计算领域里的一个热门方向。早期研究更多还是围绕无人机通信本身展开，例如通信模型、飞行能耗以及部署方式等问题。

1.3.1 无人机辅助 MEC 系统研究

Zeng^[1]等人较早分析了无人机通信中的优势和一些关键问题，为后续研究提供了基础。Mozaffari^[2]等人则从应用场景、网络结构等角度，对无人机无线网络进行了总结。Lyu^[3]等人研究了无人机作为移动基站时的部署问题，希望在有限条件下提高覆盖效果。之后，Zeng^[4]等人又分析了旋翼无人机通信过程中的能量消耗问题，指出飞行能耗在无

人机系统里占据较大比例，这一点对后续很多研究都有影响。

随着 MEC 概念逐渐成熟，研究重点也慢慢从单纯的无人机通信转向“无人机+边缘计算”结合场景。Qu^[5]等人讨论了无人机辅助 MEC 中的服务部署问题，在时延约束条件下，对服务放置和资源调度进行了联合考虑。Song^[6]等人从轨迹规划、任务卸载以及资源分配等方面，对空中移动边缘计算进行了较系统的总结。Huda^[7]等人则专门针对无人机辅助 MEC 中的计算卸载问题进行了归纳。国内方面，赵梓铭^[8]等人 and 施巍松^[9]等人从平台架构以及发展方向等角度，对边缘计算相关研究进行了总结；刘芳正^[10]等人研究了无人机基站部署问题；王侃^[11]等人围绕无人机辅助边缘计算中的轨迹规划和资源分配进行了综述；巨涛^[12]等人则进一步研究了多无人机场景下的任务卸载与路径优化问题。

目前无人机辅助 MEC 在覆盖灵活性和任务处理效率方面确实有优势。不过，很多研究还是建立在较理想化的条件下，比如默认用户位置已知、信道状态变化较稳定，或者任务到达过程比较规律。真实环境下这些条件往往很难完全满足。尤其是在动态场景中，轨迹控制、任务卸载和能耗约束之间会互相影响，系统优化难度会更高一些。

1.3.2 计算卸载与资源分配策略研究

计算卸载和资源分配一直是 MEC 研究中的核心问题。Feng^[13]等人对移动边缘计算中的计算卸载问题进行了较系统的总结，并指出时延、能耗以及资源限制之间存在明显的相互制约关系。Liu^[14]等人研究了多用户场景下的计算卸载与资源分配问题，分析了不同资源分配方式对系统性能的影响。Xu^[15]等人则围绕多用户长期任务卸载问题展开研究，对动态环境下的资源调度进行了讨论。这类研究大多仍以优化方法为主，在静态或者准静态场景下通常能够取得较好的效果。

但在无人机辅助场景下，问题会变得更加复杂。因为无人机本身是移动的，所以轨迹、通信和计算之间会产生较强耦合关系。Wang^[16]等人将无人机移动、用户调度以及任务卸载联合建模，并利用 DDPG 算法进行求解。之后，Wang 等人^[17]又进一步研究了动态轨迹控制问题。Zhao^[18]等人则在多无人机场景下，引入多智能体深度强化学习框架，对轨迹、卸载和资源管理进行联合优化。更多研究中，张海波^[19]等人分析了软件定义网络与边缘计算结合场景下的任务卸载问题；谢万城^[20]等人提出了基于 PPO（Proximal Policy Optimization）的任务卸载方案；Peng^[21]等人则研究了 MIMO（Multiple-Input Multiple-Output）辅助多无人机 MEC 系统中的时延优化问题。

总体来看,传统优化方法在模型规模较小时效果还比较稳定,但随着系统状态和动作空间不断扩大,求解复杂度会迅速增加。有些启发式算法虽然能够降低求解难度,不过往往容易陷入局部最优,而且对环境变化的适应能力也比较有限。因此,如何在动态环境下实现在线、自适应的任务卸载与资源调度,逐渐成为当前研究里的重点问题。

1.3.3 强化学习在无人机辅助 MEC 中的应用

强化学习的发展,为解决无人机辅助 MEC 中的动态优化问题提供了新的思路。Mnih^[22]等人提出深度 Q 网络(Deep Q Network, DQN)之后,深度强化学习开始被广泛应用到复杂决策问题中。Lillicrap^[23]等人提出 DDPG 算法,使强化学习能够处理连续动作空间问题。随后, Fujimoto^[24]等人提出 TD3 (Twin Delayed Deep Deterministic Policy Gradient),用于缓解 Q 值过估计问题; Schulman^[25]等人提出 PPO 算法,提高了策略更新过程中的稳定性; Haarnoja^[26]等人提出 SAC 算法,通过最大熵机制增强策略探索能力; Lowe^[27]等人提出 MADDPG,为多智能体协同决策提供了新的方法。

在无人机辅助 MEC 场景中, Wang^[16]等人较早将 DDPG 用于计算卸载优化问题。之后, Wang^[17]等人利用深度强化学习实现了动态轨迹控制。Zhao^[18]等人则采用多智能体强化学习处理多无人机任务卸载问题。除此之外, Huda^[7]等人、Song^[6]等人、Peng^[21]等人以及王侃^[11]等人等综述类研究也都提到,强化学习已经逐渐成为处理轨迹规划、任务卸载以及资源分配问题的重要方法。

不过,强化学习方法本身也存在一些现实问题。比如训练过程通常需要大量样本和交互次数,训练时间会比较长;当用户数量或者场景规模发生变化时,模型泛化能力也容易下降。另外,多目标优化中的奖励函数设计往往依赖人工经验,如果奖励设置不合理,最终学习到的策略效果也会受到影响。

1.3.4 研究现状总结与问题提炼

结合目前研究可以发现,无人机辅助 MEC 在计算卸载和资源优化方面已经有了不少成果,不过实际应用里还是存在一些比较明显的问题。

(1) 收敛速度和样本效率还有待改进。Peng^[28]等人在关于深度强化学习卸载方法的综述中提到,很多强化学习算法都比较依赖大量交互数据。像 DDPG 这种连续动作算法,在状态空间维度较高时,训练过程往往会比较慢,需要经过较长时间才能慢慢稳定下来。Hortelano^[29]等人也指出,强化学习训练本身容易受到环境随机性影响,不同训练

轮次之间可能出现较大的结果波动。有时候训练样本不够，模型甚至会出现训练一段时间后性能反而下降的情况，奖励值上下波动也比较明显。这类问题放在真实无人机系统里会更加突出，因为现实环境很难像仿真平台一样提供大量重复训练机会。

（2）多目标之间缺少灵活的协调方式。目前很多研究都会把时延、能耗等指标通过加权方式组合成一个统一目标，再利用算法进行优化。不过这些权重参数大多还是人工设定的。Gronauer^[30]等人在多智能体强化学习相关研究中提到，不同场景下，各目标的重要程度其实会不断变化。如果权重始终固定，策略在复杂环境里的适应能力会受到影响。比如无人机剩余电量较低时，系统可能更需要优先考虑能耗；但在应急任务或者高实时性场景下，时延又会成为主要目标。固定权重很难同时兼顾这些动态变化。

（3）对动态环境的适应能力还不够。很多现有工作在建模时，通常默认用户移动速度较慢，或者无线信道变化比较平稳。Luo^[31]等人在移动边缘计算卸载研究中也提到，大部分算法验证仍然是在相对理想化的环境中完成的。但真实场景其实复杂得多。用户位置变化、突发任务增加、信道波动甚至环境遮挡等情况都比较常见。一旦环境变化速度过快，一些已经训练好的策略就容易出现性能下降的问题。尤其在复杂场景下，模型有时会出现决策滞后，无法及时调整卸载行为。

（4）模型泛化能力仍然有限。Ismail^[32]等人在边缘计算资源调度研究中指出，很多强化学习模型对训练环境依赖比较明显。目前不少无人机辅助 MEC 算法，基本都是在固定用户数量、固定区域大小或者固定参数条件下训练得到的。当训练环境发生变化，比如用户分布不同了、系统规模扩大了，原来的策略往往难以直接迁移。有些模型在训练场景中效果还不错，但换一个环境后，时延和能耗指标会下降比较明显，说明模型跨场景适应能力还有进一步改进空间。

结合以上问题，本文将围绕单无人机辅助 MEC 场景展开研究。重点会放在状态空间设计、奖励函数优化以及训练稳定性几个方面，希望让 DDPG 在动态环境下能够得到更加稳定的联合优化效果。

1.4 研究意义与内容

1.4.1 理论意义

本文的研究主要围绕无人机辅助 MEC 场景下的联合优化问题展开。在已有研究中，很多传统优化方法更适合静态环境，而对于连续动作、动态状态变化较明显的场景，处

理起来会比较困难。因此，本文尝试将深度强化学习方法引入到无人机辅助 MEC 系统中，重点研究 DDPG 算法在连续动作空间下的应用效果。

另外，本文没有把路径规划和任务卸载分开处理，而是将两部分统一建模。因为在实际场景中，无人机飞行位置会影响通信质量，而任务卸载策略又会反过来影响无人机的能耗和后续飞行能力，两者之间本身就存在较强关联。如果单独优化其中一个部分，整体效果往往不太稳定。基于这一点，本文将联合优化问题建模为马尔可夫决策过程，并对连续动作空间进行了设计，例如卸载比例和飞行方向都采用连续化表示方式。

除此之外，奖励函数部分也进行了相应调整。本文不仅考虑任务时延，还同时加入了无人机能耗以及任务丢弃惩罚等因素。不同权重设置对训练结果会产生一定影响，因此实验中也对相关参数进行了分析。这部分内容主要是希望让奖励设计更加贴近实际场景，而不是只关注单一指标。

1.4.2 实际意义

本文研究的场景主要面向一些传统网络覆盖能力不足、或者网络压力较大的环境。例如在灾害救援场景中，部分地面通信设施可能已经失效，无人机能够在较短时间内飞到目标区域上空，为救援人员提供服务。对于生命探测、视频回传这类实时性要求较高的任务，无人机可以根据任务需求动态分配计算资源。此类任务通常要求端到端时延控制在秒级以内，并保证较高任务完成率，对计算资源调度能力提出了较高要求。

在大型临时活动场景下，例如演唱会、体育赛事等，短时间内用户数量会迅速增加，周边基站容易出现拥塞。这种情况下，无人机能够作为空中计算节点，对部分业务进行分流，缓解地面网络压力。对于直播、在线互动等对时延较敏感的应用，也能够提供一定帮助。在用户密集场景中，系统需要同时满足大量用户的接入需求，并尽可能降低任务处理时延和网络拥塞概率。另外，偏远地区或者基础设施尚不完善的道路场景中，无人机辅助 MEC 系统也具有应用空间。例如车联网环境下，部分区域可能无法稳定接入边缘服务，这时无人机可以为车载终端提供临时导航更新、道路预警等功能。相关业务通常要求通信链路保持较高可靠性，并能够及时完成任务处理。总体来看，无人机未来不仅可以承担通信中继任务，也可能逐渐向“通信+计算+感知”一体化方向发展。

1.4.3 主要研究内容

论文的研究内容主要包括以下四个部分：

（1）建立无人机辅助 MEC 系统模型。本文构建了一个单无人机、多用户的边缘计算系统模型。无人机上搭载了 MEC 服务器，对地面用户提供计算服务。系统中也对通信模型、计算模型以及无人机能耗模型进行了定义，包括本地计算时延、任务卸载时延以及飞行、悬停和计算过程中的能量消耗等内容。

（2）问题形式化与 MDP 建模。将无人机路径规划与任务卸载联合优化问题建模为马尔可夫决策过程。状态空间中包括无人机位置、剩余电量以及任务数据量等信息；动作空间包括无人机飞行方向和任务卸载比例。奖励函数则由任务处理时延、无人机能耗以及任务丢弃惩罚共同构成。

（3）设计基于 DDPG 的联合优化算法。本文对 DDPG 算法在无人机辅助 MEC 场景中的应用过程进行了设计。包括 Actor 网络与 Critic 网络结构、状态归一化处理方式、动作映射方式以及训练流程等内容。网络结构采用多层全连接神经网络，并使用 ReLU 激活函数完成特征映射。训练过程中包含经验存储、交互采样以及参数更新等步骤。

（4）仿真实验与性能验证。本文基于 Python 与 PyTorch 搭建了仿真环境，对无人机与用户之间的交互过程进行了模拟。同时设置了本地计算、随机卸载、贪婪式最短路径以及固定无人机位置的 DRL 方法作为对比算法。实验部分主要从收敛情况、系统能耗、平均时延、任务完成率以及不同参数变化等方面，对算法性能进行分析，并通过轨迹可视化观察无人机的动态移动行为。

1.5 论文组织结构

本文共分为四个章节，各章节的内容安排如图 1.1 所展示。




图 1.1 论文组织架构图

第1章为绪论部分。主要介绍无人机辅助移动边缘计算的发展背景以及当前研究的大致情况。随着边缘计算场景越来越复杂，传统固定式边缘节点在灵活性方面开始出现一些限制。无人机具备移动能力和较好的空地通信条件，所以逐渐被用于辅助边缘计算任务处理。不过，在实际环境中，无人机本身也会受到能量、信道状态等因素影响，系统优化难度会明显增加。本章还对无人机辅助 MEC、任务卸载、资源分配以及强化学习等研究进行了整理，并结合现有研究，分析了目前仍然存在的一些问题，例如训练稳定性不足、模型泛化能力有限等。

第2章主要介绍论文中涉及的一些理论基础和关键技术。内容包括移动边缘计算的基本概念、典型系统结构以及任务卸载的常见方式。同时，也对无人机辅助边缘计算中的一些典型场景进行了简单分析，例如临时热点区域服务、车联网辅助通信以及灾害场景中的应急计算等。后续章节会使用强化学习算法，本章还对强化学习中的状态、动作、奖励函数以及马尔可夫决策过程等概念进行了介绍。另外，也对 DQN、Actor-Critic 以及 DDPG 等算法的基本原理进行了说明。之所以专门介绍这些算法，是因为后面的联合优化模型需要处理连续动作问题。

第3章主要介绍系统模型和基于 DDPG 的联合优化算法设计，也是全文中比较核心的一部分。本章先建立无人机辅助 MEC 系统模型，包括系统架构、通信模型、任务计算模型以及无人机能耗模型。模型中还考虑了无人机移动、任务卸载以及能量消耗之间的相互影响的问题。然后，将无人机轨迹优化与任务卸载问题统一描述为马尔可夫决策过程，对状态空间、动作空间以及奖励函数进行定义。其中，状态空间包含无人机的位置、剩余电量以及用户任务数据量等相关信息；动作空间则包括无人机移动方向和任务卸载比例。考虑到动作属于连续变量，本文选择 DDPG 算法进行求解。后半部分还介绍了网络结构设计、经验回放机制、目标网络更新以及动作映射等实现过程，并给出了算法训练流程与伪代码。

第4章为仿真实验与结果分析部分。本章主要对前面提出的模型和算法进行实验验证。实验部分给出了仿真环境配置、参数设置以及对比算法的实现方式，同时对训练过程进行了分析。本章还从平均时延、系统能耗以及任务完成率等多个指标，对不同算法进行了对比测试。除此之外，还进一步分析了用户数量、任务数据量以及无人机算力变化对系统性能带来的影响。实验结果可以看到，不同参数条件下，系统表现会出现一定变化。而 DDPG 算法能够根据环境状态动态调整无人机移动行为和任务卸载比例。

2 相关技术综述

本章主要对论文中涉及的几个核心技术做一个整理和说明，内容包括移动边缘计算、无人机辅助边缘计算，以及强化学习相关理论。近几年，边缘计算在低时延任务中的应用越来越多，尤其是在物联网设备数量不断增加之后，传统云计算“距离远、响应慢”的问题变得更加明显。把计算资源放到离用户更近的位置，可以减少数据传输时间，这也是 MEC 受到关注的原因。单纯依赖固定边缘节点也存在一些限制，比如覆盖范围有限、部署位置不够灵活。在一些临时性场景或者基础设施不足的区域，传统 MEC 很难稳定提供服务。无人机的加入在一定程度上解决了这个问题。无人机可以快速移动，还能动态调整位置，相当于把边缘服务器“带到用户附近”。这样一来，系统在覆盖能力和服务灵活性方面都会更适合动态环境。仅靠传统优化方法处理无人机轨迹、任务卸载和资源调度，往往会遇到模型复杂、实时性不足的问题。特别是在环境不断变化的情况下，很多参数很难提前准确获取。强化学习，尤其是深度强化学习，在这类问题中表现出较强的适应能力。它不需要完全依赖精确模型，而是通过不断与环境交互来学习决策策略，更适合处理连续动态优化问题。后续章节会围绕这些内容展开系统建模和算法设计，所以本章主要起到理论铺垫的作用。

2.1 边缘计算

2.1.1 移动边缘计算概述

移动边缘计算（Mobile Edge Computing, MEC）是近几年发展较快的一种分布式计算方式。传统云计算计算能力强，但很多数据都需要传输到远端云中心处理，数据来回传输会带来比较明显的时延问题。尤其是在一些对实时性要求较高的场景中。MEC 的出现，本质上就是把计算资源从远端“搬”到离用户更近的位置，比如基站附近或者接入点附近。这样用户设备产生的数据不需要全部上传到远端云服务器，在边缘侧就能够完成一部分处理。

MEC 概念最早由欧洲电信标准化协会（ETSI）在 2014 年提出。目前，MEC 已经成为 5G 网络中的一个重要组成部分。很多低时延业务，比如 AR、视频分析、智能驾驶等，都比较依赖边缘计算能力。因为这些业务如果全部交给远端云处理，通信时延会比较明显，用户体验也容易受到影响。

（1）MEC 的系统架构

典型的 MEC 系统一般由三部分组成，分别是用户终端、无线接入网络以及 MEC 服务器。MEC 服务器通常部署在靠近用户的位置，例如基站侧或者网络边缘节点附近。有些场景中，甚至可以直接部署在终端附近。

按照部署位置不同，MEC 系统大致可以分为基站侧 MEC、网络边缘 MEC 以及终端侧 MEC。图 2.1 给出了移动边缘计算系统的基本结构。




图 2.1 移动边缘计算系统架构示意图

在 MEC 系统中，用户设备会把计算任务上传到边缘服务器处理，处理完成后再将结果返回终端。这样一来，部分对时延要求较高的任务可以直接在边缘侧完成，不需要再经过核心网络传输到远端云中心。至于一些计算量特别大的任务，仍然可以交给云端处理。所以整个系统实际上形成了一种“云—边—端”协同结构。

另外，部分 MEC 系统还支持设备到设备（D2D）通信。也就是说，一些终端之间可以直接交换数据或者共享资源，而不需要全部依赖基站转发。这种方式在网络拥塞场景下会更灵活一些。

（2）MEC 的核心技术

MEC 系统里比较核心的部分，主要包括计算卸载、资源分配以及任务调度。这几个部分之间本身就有联系，一个环节处理不好，整体性能都会受到影响。

（a）计算卸载

计算卸载可以理解为“任务到底放在哪里处理”。终端设备本地算，还是交给边缘服务器算，这就是计算卸载要解决的问题。

目前常见的卸载方式主要有两类。一类是二元卸载模型。这种模型比较简单，任务只能全部本地执行，或者全部卸载到边缘服务器处理，不能拆分。它更适合一些完整性要求较高的任务。

另一类是部分卸载模型。对于一些规模较大、可以拆分的任务，可以把任务划分成不同部分。一部分放在本地处理，另一部分交给边缘服务器处理。这种方式会更加灵活。实际场景中，很多任务之间还存在依赖关系，例如任务执行顺序不能随意改变。这种情况下通常会使用任务图模型进行描述。不过这部分内容相对更复杂，并不属于本文重点研究范围。

（b）资源分配

资源分配主要考虑的是“有限资源怎么分”。MEC 服务器的计算资源和通信带宽本身是有限的，但系统中往往会有多个用户同时请求服务。

在单用户场景下，问题相对简单一些，主要考虑任务怎么卸载、资源怎么分配。但在多用户环境中，不同用户会同时竞争通信和计算资源，问题复杂度会明显增加。尤其是在时延和能耗都需要考虑的情况下，资源分配通常会变成一个比较复杂的优化问题。很多研究会采用传统优化方法、启发式算法或者机器学习方法来求解。

（c）任务调度

任务调度关注的是“谁先执行、什么时候执行”。因为不同任务的数据量、计算复杂度以及时延要求都不一样，所以系统需要动态安排任务执行顺序。

目前比较常见的调度方式包括优先级调度、队列调度以及基于学习的方法。例如最短剩余时间优先、最早截止时间优先等，都属于比较典型的调度策略。不同场景下，适合的调度方式也会有所区别。

（3）MEC 的关键挑战

虽然 MEC 已经发展了很多年，但实际应用过程中还是存在不少问题。一个比较明显的问题，就是边缘节点覆盖范围有限。尤其是在用户密度较高或者偏远区域场景中，仅依赖固定 MEC 服务器往往很难实现稳定覆盖。这也是后面无人机辅助 MEC 研究越来越多的原因。

另外，不同终端设备对资源的需求差异很大。有的任务更关注时延，有的任务更关

注能耗，还有一些任务本身计算量就特别大。在有限资源条件下，如何同时兼顾时延、能耗以及公平性，其实并不容易。

用户移动性也会带来新的问题。例如用户在不同 MEC 区域之间移动时，任务可能需要在不同边缘服务器之间迁移。如果处理不好，很容易出现任务中断或者服务质量下降的问题。

2.1.2 无人机辅助边缘计算

无人机辅助边缘计算，本质上就是把无人机技术和 MEC 结合在一起。传统 MEC 节点大多是固定部署的，但无人机可以移动，所以灵活性会更高一些。近年来，越来越多研究开始尝试把 MEC 服务器直接部署到无人机上，通过无人机为地面用户提供临时通信和边缘计算服务。

（1）无人机作为空中边缘节点的优势

（a）部署灵活

无人机最大的特点之一，就是能够快速移动到目标区域。像灾害救援、大型集会或者临时通信中断场景中，地面基础设施可能已经无法正常工作，这时候无人机能够在短时间内完成部署，快速建立临时通信和计算网络。任务结束之后，无人机也可以直接撤离，不需要长期维护固定设施。

（b）空地链路条件较好

无人机飞行在空中，与地面用户之间通常更容易形成视距（LoS）链路。相比复杂城市环境中的地面通信，空地通信受到障碍物影响会更小一些，路径损耗也相对较低，所以通信质量通常会更稳定。

（c）具有三维移动能力

传统基站位置是固定的，但无人机可以在三维空间中进行移动。无人机飞到哪里，会直接影响通信质量和覆盖范围。通过动态调整飞行轨迹，无人机能够主动靠近任务需求较高的区域，这也是无人机辅助 MEC 和传统 MEC 最大的区别之一。

（d）覆盖范围能够动态变化

地面用户分布通常不是固定的。传统 MEC 节点覆盖范围有限，很难实时适应用户变化。但无人机可以随着用户位置变化调整服务区域，把计算资源移动到更需要的位置。

（2）无人机辅助 MEC 的系统模型

典型的单无人机辅助 MEC 系统，一般是由一架搭载 MEC 服务器的无人和多名地面用户组成。无人机在空中飞行，用户随机分布，每个用户都会产生计算任务。

无人机在运行过程中会消耗大量能量，而且能量来源通常只有电池。飞行需要耗电，悬停需要耗电，通信和计算同样也会消耗能量。这几个部分之间其实存在明显权衡关系。比如无人机快速飞向用户区域，可以缩短通信距离，但飞行能耗会增加；如果悬停时间过长，虽然能够处理更多任务，但电量下降速度也会更快。

资源分配是系统中的一个重点问题。无人机需要同时管理通信资源和计算资源，例如带宽、发射功率以及 CPU 频率等。由于用户任务和信道状态会不断变化，所以资源分配策略也需要实时调整。

轨迹控制问题同样比较关键。无人机飞行路径会直接影响通信质量和覆盖范围。目前很多研究会把轨迹优化分成离线规划和在线自适应两类。离线规划更适合用户位置基本固定的场景，而在线轨迹控制则更适合动态环境。这类场景中，强化学习方法会更常见一些。

任务处理时延通常由上传时延、排队时延和计算时延共同组成。一般来说，任务结果返回的数据量远小于上传数据量，所以回传时延往往可以忽略。真正影响较大的，通常还是任务上传过程以及边缘服务器排队处理过程。

安全性的问题也是无人机辅助 MEC 研究中的一个方向。由于空地通信属于无线传输，更容易受到窃听或者干扰影响。另外，无人机本身也存在被攻击或者失控的风险，所以很多研究也会考虑身份认证、保密卸载以及物理层安全等问题。

（3）面临的挑战

虽然无人机辅助 MEC 具有较高灵活性，但实际应用过程中依然存在很多问题。能量限制是最现实的问题之一。大多数小型无人机续航时间并不长，但飞行、悬停、通信以及计算都会持续消耗电量。有限电池条件下，如何合理分配能量，是整个系统设计中比较难处理的问题。

空地信道变化也会增加系统不确定性。无人机飞行过程中，高度、距离以及飞行角度都会不断变化，这会导致信道状态持续波动。实际环境中的通信条件，往往没有理论模型里那么稳定。

用户任务本身也具有随机性。任务什么时候到达、数据量多大、需要多少计算资源，这些通常都无法提前准确预测。当用户数量增加时，系统状态空间会迅速变大，优化难

度也会明显提高。

另外，飞行路径和任务卸载之间本身就存在较强关联。无人机飞行位置会影响通信速率，而任务卸载策略又会影响无人机计算负载和悬停时间。两部分互相影响，如果分开处理，很容易导致整体效果下降。所以很多研究都会把轨迹规划和任务卸载放到同一个框架里联合优化。

2.2 强化学习基础

强化学习（Reinforcement Learning, RL）属于机器学习中的一个重要方向。和 supervised learning 依赖大量标签数据不同，强化学习更像是一种“边尝试边学习”的过程。智能体会不断和环境交互，通过动作获得奖励或者惩罚，再慢慢调整自己的决策方式，目标是让长期收益尽可能高。简单理解，就是系统自己在试错中寻找更合适的策略。图 2.2 展示了强化学习中智能体与环境之间的基本交互过程。



图 2.2 强化学习智能体-环境交互框架

2.2.1 马尔可夫决策过程

马尔可夫决策过程（Markov Decision Process, MDP）是强化学习中最基础的数学模型。很多强化学习问题，本质上都可以转化成 MDP 问题。它主要用来描述“当前状态—采取动作—环境变化—获得奖励”这一连续决策过程。

（1）马尔可夫性质

在一个动态系统中，如果下一时刻的状态只和当前状态有关，而和更早之前的历史状态没有关系，就认为这个过程满足马尔可夫性质。公式表达如下：

$$P(s_{t+1}|s_t, a_t, s_{t-1}, \dots, s_0) = P(s_{t+1}|s_t) \quad (2.1)$$

具备马尔可夫性质的随机过程就称为马尔可夫过程。

（2）MDP 的五元组定义

标准 MDP 通常由五个部分组成，即状态空间、动作空间、状态转移概率、奖励函

数以及折扣因子。

状态空间 S 表示系统可能出现的所有状态。在本文研究的无人机辅助 MEC 系统里，状态信息通常包括无人机当前位置、剩余电量、用户任务量以及信道状态等。

动作空间 A 表示智能体能够执行的动作。例如无人机飞行方向、移动距离、任务卸载比例以及资源分配策略等，都属于动作空间中的内容。

状态转移概率描述的是：系统在当前状态下执行某个动作后，会以多大概率转移到新的状态。这个部分主要体现环境中的随机性。

奖励函数用于评价当前动作的好坏。强化学习中的智能体会尽量选择奖励更高的动作。在本文中，奖励通常和系统总开销有关，例如时延越低、能耗越小，奖励值就会越高。

折扣因子 γ 用来衡量智能体对未来收益的重视程度。当 γ 较大时，说明系统更关注长期收益；反之则更关注当前收益。

（3）策略与价值函数

策略 π 可以理解成“在某种状态下该采取什么动作”的规则。强化学习训练的核心，其实就是不断优化策略。

状态价值函数表示：系统从某个状态出发，后续一直按照当前策略运行时，能够获得的期望累积奖励。其表达式如下：

$$V^{\pi}(s) = E_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} / S_t = s \right] \quad (2.2)$$

动作价值函数则进一步考虑了动作选择问题，即在某个状态下执行特定动作后，未来能够获得多少累计收益：

$$Q^{\pi}(s, a) = E_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} / S_t = s, A_t = a \right] \quad (2.3)$$

很多强化学习算法，本质上都是围绕价值函数展开的。

（4）贝尔曼方程

贝尔曼方程反映了价值函数之间的递归关系。简单来说，就是“当前价值 = 当前奖励 + 未来价值”。

状态价值函数对应的贝尔曼方程如下：

$$V^{\pi}(s) = \sum_a \pi(a|s) \sum_{s',r} P(s',r|s,a) [r + \gamma V^{\pi}(s')] \quad (2.4)$$

最优价值函数满足贝尔曼最优方程：

$$V(s) = \max_a \sum_{s',r} P(s',r|s,a) [r + \gamma V(s')] \quad (2.5)$$

贝尔曼方程实际上也是后面很多强化学习算法的重要理论基础。

2.2.2 Q 学习与深度 Q 网络

（1）Q 学习的基本原理

Q 学习是一种经典的值函数强化学习算法。它的特点在于不需要提前知道环境模型，只需要不断与环境交互，就可以逐步学习动作价值函数 $Q(s,a)$ 。

Q 学习最核心的部分是 Q 值更新公式：

$$Q(s,a) \leftarrow Q(s,a) + \alpha [r + \gamma \max_{a'} Q(s',a') - Q(s,a)] \quad (2.6)$$

其中， α 表示学习率。整个更新过程其实是在不断修正 Q 值估计误差。

实际训练过程中，Q 学习通常还会使用 ϵ -贪心策略平衡“探索”和“利用”。

$$\pi(a|s) = \begin{cases} 1 - \epsilon + \frac{\epsilon}{|A|}, & a = \arg \max_{a'} Q(s,a') \\ \frac{\epsilon}{|A|}, & \text{其他} \end{cases} \quad (2.7)$$

也就是说，系统大部分时间会选择当前最优动作，但偶尔也会随机探索新的动作。这种做法是为了避免智能体过早地陷入局部最优。

（2）深度 Q 网络（DQN）

传统 Q 学习采用 Q 表保存状态与动作对应关系。当状态空间较小时，这种方式还能使用。但在实际问题中，状态往往是高维甚至连续的，Q 表会迅速膨胀，很难继续使用。

DQN 将神经网络引入 Q 学习。它用神经网络近似 Q 值函数 $Q(s,a;\theta)$ 。因此，即使面对复杂状态空间，系统也能完成学习。

DQN 中有两个比较关键的技巧。一个是经验回放机制。系统会把历史交互数据存入经验池，训练时随机抽样，而不是直接按时间顺序训练。这样能够减少数据相关性，提高训练稳定性。

另一个是目标网络机制。DQN 会同时维护当前网络和目标网络。目标网络不会每

一步都更新，而是间隔一定步数再同步参数，这样可以减少训练震荡。

DQN 的损失函数如下：

$$L(\theta) = E_{(s,a,r,s') \sim D} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right] \quad (2.8)$$

算法 2.1 给出了 DQN 的训练流程。

算法 2.1 DQN 算法

Input:

状态空间 S ;

动作空间 A ;

学习率 α ;

折扣因子 γ ;

探索率 ϵ ;

回放缓冲区容量 N ;

目标网络更新周期 C

Output:

训练完成的 Q 网络 $Q(s,a;\theta)$

1. 初始化经验回放缓冲区 D ，容量为 N
 2. 用随机权重 θ 初始化当前 Q 网络 $Q(s,a;\theta)$
 3. 用权重 $\theta^- = \theta$ 初始化目标网络 $Q(s,a;\theta^-)$
 4. for episode = 1 to M do
 5. 初始化初始状态 s
 6. while s 不是终止状态 do
 7. 以概率 ϵ 选择随机动作 a ，否则选择 $a = \arg\max_a Q(s,a;\theta)$
 8. 执行动作 a ，观察奖励 r 和下一个状态 s'
 9. 将经验 (s,a,r,s') 存入 D
 10. 从 D 中随机采样小批量 B 个经验
 11. 对每个经验计算目标值 $y = r + \gamma \max_{a'} Q(s',a';\theta^-)$
 12. 对损失函数 $L = (y - Q(s,a;\theta))^2$ 执行梯度下降更新 θ
 13. 每 C 步更新目标网络： $\theta^- \leftarrow \theta$
 14. $s \leftarrow s'$
 15. end while
 16. end for
-

（3）DQN 的优势与局限

DQN 在很多离散动作任务中效果不错，例如 Atari 游戏等经典问题。不过它本身更适合离散动作空间。无人机辅助 MEC 系统中的动作往往是连续变量，例如飞行方向、移动距离、卸载比例等。这种情况下，DQN 直接处理会比较困难。再加上 DQN 还存在 Q 值过估计等问题，所以后面逐渐发展出了更适合连续控制问题的方法。

2.2.3 Actor-Critic 与深度确定性策略梯度

（1）策略梯度方法

策略梯度方法和 Q 学习属于两种不同思路。Q 学习更偏向“先学价值，再选动作”，而策略梯度方法则是直接学习策略本身。

策略梯度公式如下：

$$\nabla_{\theta} J(\theta) = E_{\pi_{\theta}} \left[\nabla_{\theta} \log \pi_{\theta}(a|s) \cdot Q^{\pi_{\theta}}(s, a) \right] \quad (2.9)$$

这种方法不依赖环境模型，所以更适合复杂动态环境。

（2）Actor-Critic 算法

Actor-Critic 算法结合了策略梯度和值函数方法的特点。

$$\nabla_{\theta} J(\theta) \approx E \left[\nabla_{\theta} \log \pi_{\theta}(a|s) \cdot \delta \right] \quad (2.10)$$

其中 $\delta = r + \gamma V(s') - V(s)$ 是时间差分误差。

Critic 网络的损失函数为：

$$L(\phi) = E \left[\left(r + \gamma V_{\phi}(s') - V_{\phi}(s) \right)^2 \right] \quad (2.11)$$

（3）深度确定性策略梯度（DDPG）

深度确定性策略梯度是在 Actor-Critic 框架基础上发展出来的强化学习算法，相对更适合处理连续动作空间问题。

DDPG 同时结合了 DQN 中的经验回放和目标网络机制，所以训练稳定性会更好。

DDPG 包含四个神经网络：

Actor 当前网络 $\mu(s; \theta^{\mu})$ ：输出确定性动作。

Actor 目标网络 $\mu'(s; \theta^{\mu'})$ ：用于稳定训练。

Critic 当前网络 $Q(s, a; \theta^Q)$ ：评估状态-动作对的价值。

Critic 目标网络 $Q'(s, a; \theta^{Q'})$ ：用于计算目标 Q 值。

DDPG 采用确定性策略，此时策略梯度简化为：

$$\nabla_{\theta^{\mu}} J \approx E_{s \sim D} [\nabla_a Q(s, a; \theta^Q)|_{a=\mu(s)} \cdot \nabla_{\theta^{\mu}} \mu(s; \theta^{\mu})] \quad (2.12)$$

Critic 网络的更新目标为：

$$y = r + \gamma Q'(s', \mu'(s'; \theta^{\mu'}); \theta^Q) \quad (2.13)$$

2.2.4 其他先进算法简介

现在连续动作强化学习方向还有不少常见算法。不同算法的训练方式不一样，适合处理的问题也会有区别。有些算法更偏向训练稳定，有些更强调探索能力。实际研究里，很多论文都会把几种算法放在一起比较，再根据具体任务选择更合适的方法。

（1）PPO

PPO（Proximal Policy Optimization）算是强化学习里面使用比较多的一类算法。很多强化学习实验、机器人控制任务里都能看到它。这个算法有一个比较明显的特点，就是训练过程相对稳定。它不会让策略一下子变化太大，而是会限制每次更新的范围。这样做的目的，其实就是防止模型在训练过程中突然“学偏”。

另外，PPO 对参数设置没有特别苛刻，实现难度也不算高，所以现在很多强化学习工作都会优先尝试它。不过，它本身属于随机策略方法，在连续动作空间里，动作是通过概率分布采样得到的。这样虽然探索能力不错，但训练效率有时候会比 DDPG 低一些，尤其是在动作维度比较大的情况下会更明显。

（2）SAC

SAC（Soft Actor-Critic）也是近几年比较常见的一种算法。它是在最大熵强化学习思想基础上发展出来的。和传统强化学习只想着“拿更高奖励”不太一样，SAC 还会鼓励智能体保持一定随机性。换句话说，它不会让模型太早固定在一种动作选择上，而是希望模型多尝试不同方案。

不过，SAC 的结构会更复杂一些。它不只是简单输出动作，还需要额外处理熵相关内容，所以训练时计算量通常更高。对硬件资源要求也会稍微大一点。如果实验规模不算特别大，有时候 DDPG 实现起来反而更直接。

（3）TD3

TD3（Twin Delayed Deep Deterministic Policy Gradient）可以理解成是在 DDPG 基础上继续改出来的算法。DDPG 虽然能处理连续动作问题，但训练时有一个比较常见的问题，就是 Q 值容易被高估。一旦 Q 值偏差太大，策略更新方向也可能跟着出问题，

训练过程会变得不稳定。

TD3 主要就是围绕这个问题做改进。它增加了两个 Critic 网络，不再只依赖一个 Q 值进行判断，而是同时参考两个网络的结果。这样能够减少误差带来的影响。除此之外，它还加入了延迟更新机制，不会每一步都更新 Actor，而是让 Critic 先学习得更稳定，再慢慢调整策略网络。

当然，TD3 结构会更复杂，训练时间也会更长。对于一些规模较小或者实现要求不高的实验，很多人还是会直接使用 DDPG。因为 DDPG 整体逻辑更简单，代码实现也更容易理解。

2.3 本章小结

本章主要对论文后面会用到的理论内容进行了整理和说明。前面部分主要围绕移动边缘计算展开，介绍了 MEC 的基本概念、系统结构以及目前比较常见的一些核心问题。MEC 把部分计算资源放到靠近用户的位置，可以减轻云端压力，也能让任务处理速度更快一些。不过，传统 MEC 节点通常部署在固定位置，覆盖范围有限，面对一些突发场景或者复杂环境时，灵活性还是不太够。像灾害救援、临时通信或者偏远地区这类场景，仅依靠地面边缘节点往往很难满足需求。

在这种背景下，无人机辅助 MEC 开始受到越来越多关注。无人机本身移动性比较强，可以快速飞到目标区域上空，为地面用户提供临时通信和计算服务。从某种程度上看，它相当于一个会移动的边缘服务器。不过，无人机系统本身也会带来新的问题。比如飞行会消耗大量能量，轨迹怎么规划、资源怎么分配，这些问题之间其实都会互相影响。如果只单独优化某一个部分，整体效果通常不会太理想。尤其在动态环境里，用户任务和无线信道一直在变化，传统固定策略往往很难长期保持稳定。

后半部分主要介绍了强化学习相关理论。论文从马尔可夫决策过程开始，对强化学习里的状态、动作、奖励这些基本概念进行了说明。之后又整理了 Q 学习、DQN、Actor-Critic 以及 DDPG 等算法的基本思想。本文里的无人机轨迹和卸载比例都属于连续变量，直接使用 DQN 会受到一定限制。所以后续算法部分主要采用 DDPG 作为核心方法。DDPG 本身结合了 Actor-Critic 结构和策略梯度思想，比较适合处理连续动作控制问题。除此之外，本章还简单介绍了 PPO、SAC 以及 TD3 等强化学习算法。这部分内容主要是为后面的算法设计做铺垫，也方便后续实验部分进行分析和对比。

3 系统模型与基于 DDPG 的联合优化算法设计

这一章主要围绕系统建模和算法设计展开，也是全文中最核心的部分。前面已经介绍了无人机辅助 MEC 以及强化学习的相关理论，这一章会进一步结合具体场景，把问题真正落到模型。

本文主要做了几件事：一是建立无人机辅助移动边缘计算系统模型，包括通信、计算以及无人机能耗等部分；二是把无人机轨迹控制和任务卸载问题统一转化成马尔可夫决策过程；三是结合连续动作特点，设计基于 DDPG 的联合优化算法，并给出训练流程和网络结构。后面的实验部分基本都是围绕本章内容展开的。

3.1 系统模型

3.1.1 系统架构

本文考虑的是一个单无人机辅助 MEC 系统。系统中包含一架搭载边缘服务器的无人机，以及多个地面用户。无人机除了具备飞行能力外，还能够提供一定的计算服务，地面用户可以把任务上传到无人机处理，也可以直接在本地终端完成计算。

设地面用户集合表示为 $U=\{1,2,\cdots,N\}$ 。其中 N 表示用户数量。

系统采用离散时间槽方式运行，每个时间槽 $\Delta t = 0.5s$ 。在一个时间槽内，无人机会移动到新的位置，然后为某一个用户提供服务。被服务的用户可以选择将部分任务卸载到无人机，其余任务仍在本地处理。

这里采用“单时间槽单用户服务”模式。虽然这种方式会降低系统并行处理能力，但模型会简单很多。对本科毕业设计来说，这种简化其实比较合理，不然状态空间和动作空间会变得特别复杂，后面训练也容易不稳定。

为了方便建模，本文作出以下假设：

（a）用户位置固定不变，并且位置已知。这个假设在灾害救援或者临时集会场景中是可以接受的。

（b）无人机飞行高度固定，只优化二维平面轨迹。这样可以减少模型复杂度。实际中很多无人机也确实会保持在固定安全高度巡航。

（c）每个时间槽内，无人机先飞行，再悬停服务用户。飞行时间相对较短，所以忽略飞行时间对服务时长的影响。

（d）所有任务的计算密度相同，也就是每比特数据需要的 CPU 周期数固定。这个假设虽然理想化，但能够降低模型复杂度。

3.1.2 通信模型

无人机与地面用户之间采用空地无线通信模型。无人机飞在空中时，与用户之间通常更容易形成视距链路（LoS），但建筑物、树木等障碍物依然可能导致非视距（NLoS）情况出现。

设无人机在时间槽 t 的位置为 $(x(t), y(t), h)$ 。

其中 h 为固定飞行高度。用户 i 的位置为 $(x_i, y_i, 0)$ 。

无人机与用户之间的三维距离为：

$$d_i(t) = \sqrt{(x(t) - x_i)^2 + (y(t) - y_i)^2 + h^2} \quad (3.1)$$

无人机与用户之间的仰角为：

$$\theta_i(t) = \arcsin\left(\frac{h}{d_i(t)}\right) \quad (3.2)$$

LoS 概率采用经典经验模型：

$$P_{LoS}(t) = \frac{1}{1 + a \exp(-b(\theta_i(t) - a))} \quad (3.3)$$

这里的 a 和 b 与环境有关。城市环境下通常取 $a=12.08$, $b=0.15$ 。可以发现，无人机距离用户越近，或者飞行高度越高，仰角会越大，此时 LoS 概率也会提高。

路径损耗模型写成：

$$PL_i(t) = \begin{cases} 20 \log_{10}\left(\frac{4\pi f_c d_i(t)}{c}\right) + \eta_{LoS}, & LoS \text{ 链路} \\ 20 \log_{10}\left(\frac{4\pi f_c d_i(t)}{c}\right) + \eta_{NLoS}, & NLoS \text{ 链路} \end{cases} \quad (3.4)$$

其中：

f_c 为载波频率（单位：Hz），本文取典型值 $f_c = 2.4 \times 10^9 \text{ Hz}$ ；

c 为光速， $c = 3 \times 10^8 \text{ m/s}$ ；

η_{LoS} 和 η_{NLoS} 分别为 LoS 和 NLoS 情况下的额外路径损耗（单位：dB），通常取

$\eta_{LoS} = 1 \text{ dB}$, $\eta_{NLoS} = 20 \text{ dB}$ 。

信道增益为：

$$g_i(t) = 10^{-PL_i(t)/10} \quad (3.5)$$

路径损耗以分贝表示，转换为线性值后，信道增益通常是一个很小的正数（数量级约为 10^{-10} 到 10^{-6} ）。

在通信资源分配方面，本文采用时分多址（TDMA）方式，每个时间槽只服务一个用户，这样能够避免带宽分配和同频干扰问题。

根据香农公式，用户上传速率为：

$$R_i(t) = B \log_2 \left(1 + \frac{P g_i(t)}{B N_0} \right) \quad (3.6)$$

其中 B 为系统带宽， P 为用户发射功率， N_0 为噪声功率谱密度。

从公式也能看出来，用户离无人机越近，信道增益越大，数据上传速率也会越高。任务上传时间自然会缩短。这个也是无人机轨迹优化的核心原因之一。

3.1.3 计算模型

每个用户在每个时间槽生成新的计算任务。 $D_i(t)$ 表示用户 i 在时间槽 t 生成的任务数据量（单位：bit）。本研究先假设任务数据量服从均匀分布或泊松分布（ $D_i(t) \sim \mathcal{U}(D_{\min}, D_{\max})$ ）。每个任务的计算密度为 C （单位：CPU 周期/bit），表示处理每比特数据所需的 CPU 周期数。本文取 $C = 5000$ 周期/bit。

本文采用部分卸载模型。设 $\lambda_i(t) \in [0,1]$ 为卸载比例，则卸载到无人机的数据量为 $\lambda_i(t)D_i(t)$ ，本地执行的数据量为 $(1 - \lambda_i(t))D_i(t)$ 。相比“全部本地”或者“全部卸载”的二元方式，部分卸载会更灵活。系统可以根据当前环境动态调整卸载比例。

（1）本地计算

用户 i 的本地 CPU 频率记为 f_i^{loc} （单位：Hz）。本文假设所有用户的本地 CPU 频率相同，即 $f_i^{\text{loc}} = f_{\text{loc}}$ 。本地计算时延为：

$$t_i^{\text{loc}}(t) = \frac{(1 - \lambda_i(t))D_i(t)C}{f_{\text{loc}}} \quad (3.7)$$

本地计算能耗与 CPU 频率的平方成正比。能耗计算公式为：

$$e_i^{\text{loc}}(t) = \kappa (f_{\text{loc}})^2 \cdot (1 - \lambda_i(t))D_i(t)C \quad (3.8)$$

其中 κ 为芯片的有效开关电容常数。实际仿真中能耗的绝对值很小，将能耗乘以一个缩放因子会便于计算。

（2）卸载计算

卸载过程包含两个阶段：任务上传和无人机计算。

上传时延为

$$t_i^{up}(t) = \frac{\lambda_i(t)D_i(t)}{R_i(t)} \quad (3.9)$$

无人机执行时延为：

$$t_i^{exe}(t) = \frac{\lambda_i(t)D_i(t)C}{F_{UAV}} \quad (3.10)$$

这里假设无人机在一个时间槽内只服务一个用户，全部计算资源只来处理当前用户的任务。

总卸载时延为：

$$t_i^{off}(t) = t_i^{up}(t) + t_i^{exe}(t) = \lambda_i(t)D_i(t) \left(\frac{1}{R_i(t)} + \frac{C}{F_{UAV}} \right) \quad (3.11)$$

本地计算和卸载计算实际上是同时进行的，所以任务总时延取二者较大值：

$$t_i(t) = \max \{ t_i^{loc}(t), t_i^{off}(t) \} \quad (3.12)$$

如果两部分时间接近，总时延通常会比较小。

（3）任务队列与任务丢弃

真实场景中，任务不一定能够在一个时间槽内处理完成。理论上，每个用户都应该维护任务队列。

不过如果把完整队列状态全部加入模型，训练复杂度会明显增加。本研究为了保证系统可实现性，假设单个时间槽内任务规模相对较小，大部分任务能够在当前时间槽内完成。这样可以减少状态维度。

当无人机电量耗尽或者通信中断时，任务会被视为失败任务。系统会给予较大的负奖励，用来避免算法频繁出现这种情况。

3.1.4 无人机能耗模型

无人机的能耗主要由三部分组成：飞行能耗、悬停能耗以及计算能耗。

（1）飞行能耗

设无人机在时间槽 t 内的飞行距离为 $\Delta d(t)$ 。为简化模型，本文假设飞行能耗与飞行距离成正比：

$$E_{fly}(t) = e_{fly} \cdot \Delta d(t) \quad (3.13)$$

其中 e_{fly} 为飞行能耗系数（单位：J/m）。飞行距离由无人机位置变化来计算：

$$\Delta d(t) = \sqrt{(x(t+1) - x(t))^2 + (y(t+1) - y(t))^2} \quad (3.14)$$

其中 $(x(t+1), y(t+1))$ 是无人机在下一个时间槽开始时的位置。无人机移动越远，飞行能耗自然越高。

（2）悬停能耗

无人机悬停过程中需要持续输出功率维持平衡。悬停能耗表示为：

$$E_{hover}(t) = P_{hover} \cdot \Delta t_{service} \quad (3.15)$$

P_{hover} 表示悬停功率。若 $\lambda=0$ ，无人机不开启悬停服务，悬停能耗为 0。

（3）计算能耗

无人机处理任务时也会产生计算能耗：

$$E_{comp}(t) = \epsilon \cdot \lambda_i(t) D_i(t) C \quad (3.16)$$

其中 ϵ 为每单位计算量的能耗系数。

（4）总能耗与电量更新

无人机在时间槽 t 的总能耗为：

$$E_{UAV}(t) = E_{fly}(t) + E_{hover}(t) + E_{comp}(t) \quad (3.17)$$

设无人机电池总容量为 E_{max} ，剩余电量 $E_{rem}(t)$ 的更新公式为：

$$E_{rem}(t+1) = E_{rem}(t) - E_{UAV}(t) \quad (3.18)$$

无人机剩余电量不能低于安全阈值，所以 $E_{rem}(t) \geq E_{min}$ 。仿真中的电量耗尽时，会让当前回合终止，并出现较大的负奖励。

3.2 问题建模与 MDP 形式化

论文前面已经完成了系统模型的建立，但仅仅有系统模型还不够。无人机到底该往哪里飞、任务该卸载多少，本质上还是一个连续决策问题。系统状态一直在变化，用户任务也不是固定不变的，传统固定规则的方法很难一直适用。

本文把无人机轨迹控制和任务卸载统一看成一个序贯决策问题，并进一步转化为马尔可夫决策过程（MDP）。这样做的目的比较直接，就是让智能体通过不断和环境交互，自己去学习什么样的动作更合理，而不是提前人为规定策略。

在强化学习框架下，系统主要由状态、动作、奖励等几个部分组成。无人机每经过一个时间槽，就会观察当前环境状态，然后输出动作。环境根据动作更新状态，并返回对应奖励。整个过程会不断循环。

这里采用的是无模型强化学习。也就是说，不需要提前知道复杂的状态转移概率，

而是让智能体在训练过程中慢慢试出来。对于这种动态环境来说，其实会更合适一些。

3.2.1 状态空间

无人机在每个时间槽都需要根据当前环境做决策，所以状态信息必须尽量能够反映系统当前情况。如果状态定义得太简单，智能体学不到有效策略；但状态维度太高，又容易导致训练特别慢，甚至不收敛。所以这里做了一个比较折中的设计。

本文将状态定义为以下几个部分：

（1）无人机当前水平位置

无人机当前位置会直接影响与用户之间的距离，也会进一步影响通信速率。位置坐标表示为 $(x(t), y(t))$ 。

（2）无人机剩余电量

电量对无人机后续行为影响很大。剩余电量过低时，如果还继续远距离飞行，很容易提前耗尽电池。这里采用归一化处理：

$$e_{rem}(t) = E_{rem}(t) / E_{max} \quad (3.19)$$

这样做主要是为了方便神经网络训练，避免不同量纲差距太大。

（3）当前用户任务数据量

任务量越大，通常意味着需要更长处理时间。同样需要将其进行归一化为 $\frac{D_{cur}(t)}{D_{max}}$ 。原本其实还考虑过把所有用户的位置和任务状态都加入状态空间，但后来发现维度会明显增加，训练速度下降比较明显，所以取消。

所以最后采用较低维状态表达。最终状态向量为：

$$s_t = \left[\frac{x(t)}{L}, \frac{y(t)}{L}, e_{rem}(t), \frac{D_{cur}(t)}{D_{max}} \right] \quad (3.20)$$

这里的 L 表示区域边长，用于位置归一化。

整个状态维度只有 4 维，训练会稳定很多。后面实验里其实也能看到，低维状态下收敛速度会更快。

3.2.2 动作空间

无人机在每个时间槽主要做两件事：

一件是决定怎么飞，另一件是决定任务卸载多少。所以动作空间也分成两部分。飞行控制采用二维位置增量表示为 $(\Delta x(t), \Delta y(t))$ 。

无人机移动距离不能无限大，需要满足最大速度约束： $\sqrt{(\Delta x)^2 + (\Delta y)^2} \leq v_{\max} \Delta t$

如果飞行超出边界，系统会自动裁剪位置。除了飞行，还需要决定任务卸载比例 $\lambda(t) \in [0, 1]$ 。当 $\lambda=0$ 时，表示全部本地计算；当 $\lambda=1$ 时，表示全部卸载到无人机。所以最终动作向量可以写成 $a_t = [\Delta x(t), \Delta y(t), \lambda(t)]$ 。

整个动作空间都是连续变量。这也是为什么本文选择 DDPG 算法，而不是 DQN。因为 DQN 更适合离散动作。如果硬要把飞行方向和卸载比例全部离散化，动作数量会爆炸，训练会特别麻烦。

3.2.3 奖励函数

奖励函数其实是强化学习里最关键的部分之一。奖励设计得合理，智能体才知道自己该往哪个方向学习。如果奖励设计不好，很容易出现一些奇怪策略。比如无人机一直停着不动，或者为了省电完全不服务用户。本文希望同时兼顾两个目标：

一个是降低任务处理时延；另一个是减少无人机能耗。

所以系统开销定义为：

$$C(t) = \alpha \cdot \frac{t_i(t)}{T_{\max}} + \beta \cdot \frac{E_{UAV}(t)}{E_{\max}} \quad (3.21)$$

其中：

$t_i(t)$ 为当前服务用户的任务处理时延；

$T_{\max}$ 为参考时延上限；

$E_{UAV}(t)$ 为无人机本时间槽总能耗；

α 和 β 为权重系数，满足 $\alpha + \beta = 1$ ，可再调整。

即时奖励为 $r_t = -C(t)$ 。这样一来，最大化奖励其实就等价于最小化系统开销。除了基础奖励外，系统还增加了一些惩罚项。

无人机电量耗尽： $r_t = -10$ ，并直接结束当前回合；

任务丢弃时： $r_t = -5$ ；

无人机飞出边界时： $r_t = -1$ ；

同时把位置拉回边界。这些惩罚主要是为了防止训练过程中出现不合理行为。实际训练时，如果不加边界惩罚，无人机有时候会乱飞。

3.2.4 优化目标

强化学习的目标，其实就是让智能体找到一个长期收益最大的策略。本文希望无人机在长期运行过程中，既尽量降低任务时延，也不要电量消耗得太快。优化目标写成长期累积折扣奖励：

$$J=E_{\pi}\left[\sum_{t=0}^{\infty}\gamma^t r_t\right] \quad (3.22)$$

其中 $\gamma \in [0,1)$ 为折扣因子。 γ 较大时，智能体会更关注长期收益； γ 较小，则会偏向眼前收益。本文实验中设置 $\gamma=0.9$ 比较常见，也能兼顾当前收益和长期策略稳定性。

3.3 基于 DDPG 的联合优化算法设计

3.3.1 DDPG 算法原理

前面已经把整个问题转成了 MDP 形式，但问题还没真正解决。接下来需要考虑的是：无人机怎么学会“自己做决策”。这类问题如果直接用传统优化方法，其实会越来越难处理。原因很简单，动作不是离散的。无人机飞行方向、移动距离、任务卸载比例这些变量全部都是连续值。动作空间一大，普通 DQN 这种方法就不太适合了。

本文选用的是 DDPG 算法，全称 Deep Deterministic Policy Gradient。这个算法是 Lillicrap^[23] 等人在 2016 年提出的，比较适合连续控制问题。像无人机轨迹控制、机械臂运动控制这类任务里都比较常见。DDPG 本质上还是强化学习，但它不像传统 Q-learning 那样“枚举动作”，而是直接输出连续动作，所以训练效率会高很多。

（1）Actor-Critic 架构

DDPG 采用 Actor-Critic 架构，包含两个核心网络：

Actor 网络 $\mu(s; \theta_{\mu})$ ：输入状态 s ，输出确定性动作 $a=\mu(s)$ 。Actor 负责根据当前状态做出决策。

Critic 网络 $Q(s,a; \theta_Q)$ ：输入状态 s 和动作 a ，输出该状态-动作对的 Q 值估计。Critic 负责评价 Actor 做出的动作的好坏。

Actor 产生动作，Critic 评价动作。这种结构像是“演员”在“评论家”的指导下不断改进自己的表演。

（2）确定性策略与随机策略的区别

传统随机策略一般会输出一个概率分布。例如： $\pi(a | s)=N(\mu(s), \sigma^2)$ 。然后再从这个分布里随机采样动作。这种方法探索能力确实强，但计算会比较慢。DDPG 不一样。它

直接输出确定动作： $a=\mu(s)$ 。不需要再采样。这样效率会高很多。特别是在连续动作空间下，优势会更明显。不过问题也很直接：如果动作完全固定，智能体容易“只会一种策略”。所以训练时会额外加入噪声，让无人机偶尔尝试新的动作。

（3）经验回放机制

强化学习有一个比较麻烦的问题。连续时间步产生的数据相关性很强。比如无人机上一秒在区域左边，下一秒大概率还在附近。这样训练数据会特别相似，容易导致网络训练不稳定。DDPG用了经验回放机制来处理这个问题。每次交互产生的数据 (s, a, r, s') 存储到一个经验缓冲区。训练时，再随机抽取一批数据更新网络，而不是直接按时间顺序训练。这样有两个好处。一个是打乱数据相关性。另一个是老数据还能重复利用。否则很多样本只用一次就浪费了。

（4）目标网络与软更新

如果网络参数更新太快，训练过程会很容易震荡。有时候前一轮学到的东西，后一轮又全忘了。DDPG里面专门用了目标网络来缓解这个问题。系统会维护两套网络，当前网络和目标网络。目标网络不会立刻跟着更新，而是慢慢靠近当前网络。更新公式为：

$$\theta^{Q'} \leftarrow \tau \theta^Q + (1-\tau) \theta^{Q'}, \quad \theta^{\mu'} \leftarrow \tau \theta^{\mu} + (1-\tau) \theta^{\mu'} \quad (3.23)$$

这种渐进式的更新会提高训练的稳定性。

（5）Critic 网络更新

Critic 网络主要负责学习 Q 值。目标 Q 值采用贝尔曼方程计算：

$$y = r + \gamma Q'(s', \mu'(s'; \theta^{\mu'}); \theta^{Q'}) \quad (3.24)$$

Q' 和 μ' 为目标网络。Critic 网络的损失函数为均方贝尔曼误差：

$$L(\theta^Q) = E_{(s,a,r,s') \sim D} [(y - Q(s,a;\theta^Q))^2] \quad (3.25)$$

训练时不断最小化这个误差。如果误差越来越小，说明 Critic 对动作价值的判断会越来越准确。

（6）Actor 网络更

Actor 更新的目标更直接。它希望 Critic 给自己的动作打更高分。策略梯度表达式为：

$$\nabla_{\theta^{\mu}} J \approx E_{s \sim D} [\nabla_a Q(s,a;\theta^Q)|_{a=\mu(s)} \cdot \nabla_{\theta^{\mu}} \mu(s;\theta^{\mu})] \quad (3.26)$$

Critic 会告诉 Actor：“动作往哪个方向改，会得到更高奖励。”然后 Actor 就朝这个方向调整参数。训练不断重复之后，无人机的动作会越来越合理。

3.3.2 网络结构设计

本小节描述 Actor 网络和 Critic 网络的结构。

（1）Actor 网络结构

Actor 网络的输入是状态向量，维度为 4（归一化后的坐标、电量、任务数据量）。输出是动作向量，维度为 3（ $\Delta x, \Delta y, \lambda$ ）。

网络结构如下：

输入层：4 个神经元；

隐藏层 1：128 个神经元，激活函数为 ReLU；

隐藏层 2：128 个神经元，激活函数为 ReLU；

输出层：3 个神经元，激活函数为 tanh（输出范围 [-1, 1]）；

输出层之后需要映射，将 tanh 输出转换为实际动作值为 $\Delta x = \text{output}_0 \cdot v_{\max} \Delta t$ ；
 $\Delta y = \text{output}_1 \cdot v_{\max} \Delta t$ ； $\lambda = (\text{output}_2 + 1)/2$ 。

ReLU 激活函数的表达式为 $\text{ReLU}(x) = \max(0, x)$ 。tanh 激活函数的表达式为 $\tanh(x) = (e^x - e^{-x}) / (e^x + e^{-x})$ 。这样就能保证动作始终在合理范围内。

（2）Critic 网络结构

Critic 网络输入的是状态和动作拼接后的向量。维度为 4+3=7。输出是标量 Q 值。

网络结构如下：

输入层：7 个神经元

隐藏层 1：128 个神经元，激活函数为 ReLU；

隐藏层 2：128 个神经元，激活函数为 ReLU；

输出层：1 个神经元，无激活函数；

Critic 网络的输出没有限制，可以是任意实数。

3.3.3 探索噪声

训练初期，如果无人机一直按固定动作飞，很容易陷入局部最优。比如只在区域中心附近活动，不愿意探索远处用户。所以训练阶段需要加入随机探索。本文采用 OU 噪声。OU 噪声比较适合无人机这种“具有惯性”的系统。它不会像普通高斯噪声那样突然大幅跳变，而是会连续变化。其表达式为：

$$dx_t = \theta(\mu - x_t)dt + \sigma dW_t \quad (3.28)$$

其中 θ 为回归速率， μ 为均值， σ 为波动强度， dW_t 为维纳过程。离散时间的递推公式为：

$$x_{t+1} = x_t + \theta(\mu - x_t)\Delta t + \sigma\sqrt{\Delta t} \cdot N(0,1) \quad (3.29)$$

本文取 $\mu=0$ ， $\theta=0.15$ ， $\sigma=0.2$ 。

3.3.4 超参数设置

算法的主要超参数及其取值如表 3.2 所示。

表 3.2 算法的主要超参数及其取值

超参数	符号	取值
Actor 学习率	α_μ	1×10^{-4}
Critic 学习率	α_Q	1×10^{-3}
折扣因子	γ	0.99
软更新系数	τ	0.001
经验回放缓冲区容量	M	10^5
小批量大小	B	64
最大训练回合数	E	2000
每回合最大步数	T	200
探索噪声参数	θ, σ	0.15, 0.2
更新开始步数	U	1000
目标网络更新频率	-	每步软更新

3.3.5 算法训练流程

完整的训练流程如算法 3.1 所示。

算法 3.1 DDPG 算法

输入：环境参数，超参数

输出：训练好的 Actor 网络参数 θ^μ

1. // 初始化
2. 随机初始化 Actor 当前网络 $\mu(s; \theta^\mu)$ 和 Critic 当前网络 $Q(s, a; \theta^Q)$
3. 初始化目标网络： $\theta^{\mu'} \leftarrow \theta^\mu, \theta^{Q'} \leftarrow \theta^Q$
4. 初始化经验回放缓冲区 D，容量为 M
- 5.
6. // 开始训练
7. for episode = 1 to E do
8. // 初始化环境

```
9.      重置无人机位置为起点（如区域中心），剩余电量  $E_{\max}$ 
10.     重置用户任务队列，生成初始任务
11.     获取初始状态  $s$ （归一化）
12.
13.     for  $t = 1$  to  $T$  do
14.         // 动作选择
15.         根据当前策略和噪声选择动作：
16.              $a_{\text{raw}} = \mu(s; \theta^{\mu}) + N_t$  //  $N_t$  为 OU 噪声
17.         将  $a_{\text{raw}}$  映射到实际动作： $\Delta x, \Delta y, \lambda$ 
18.
19.         // 确定当前服务用户（轮询）
20.          $i = (\text{episode} - t) \bmod N + 1$ 
21.
22.         // 执行动作，与环境交互
23.         更新无人机位置： $x \leftarrow x + \Delta x, y \leftarrow y + \Delta y$ （边界裁剪）
24.         计算传输速率  $R_i(t)$ （公式 3.6）
25.         计算本地时延和卸载时延（公式 3.7, 3.11）
26.         计算总时延  $t_i(t)$ （公式 3.12）
27.         计算无人机能耗（公式 3.17）
28.         计算奖励  $r$ （公式 3.21, 3.22）
29.         更新剩余电量  $E_{\text{rem}}$ 
30.         获取下一状态  $s'$ 
31.
32.         // 存储经验
33.         将经验  $(s, a_{\text{raw}}, r, s')$  存入  $D$ 
34.
35.         // 网络更新（当经验足够多时）
36.         if  $\text{len}(D) \geq U$  then
37.             从  $D$  中随机采样  $B$  个经验
38.             // 更新 Critic 网络
39.             计算目标  $Q$  值： $y_j = r_j + \gamma Q'(s_{\{j+1\}}, \mu'(s_{\{j+1\}}; \theta^{\mu'}); \theta^{\{Q'\}})$ 
40.             计算损失  $L = (1/B) \sum (y_j - Q(s_j, a_j; \theta^Q))^2$ 
41.             使用 Adam 优化器更新  $\theta^Q$ 
```

```

42.          // 更新 Actor 网络
43.          计算策略梯度  $\nabla_{\theta^{\mu}} J$  (公式 3.27)
44.          使用 Adam 优化器更新  $\theta^{\mu}$ 
45.          // 软更新目标网络
46.           $\theta^{\{Q'\}} \leftarrow \tau \theta^Q + (1-\tau) \theta^{\{Q'\}}$ 
47.           $\theta^{\{\mu'\}} \leftarrow \tau \theta^{\mu} + (1-\tau) \theta^{\{\mu'\}}$ 
48.      end if
49.
50.      // 终止条件判断
51.      if  $E_{rem} < E_{min}$  then
52.          给予额外惩罚  $r = -10$ , 并 break
53.      end if
54.
55.       $s \leftarrow s'$ 
56.  end for
57.
58.  // 每 100 个回合输出一一次平均奖励
59.  if  $episode \% 100 == 0$  then
60.      打印 episode 和平均奖励
61.  end if
62. end for
64. return  $\theta^{\mu}$ 

```

训练时，噪声会加到动作上。这样无人机偶尔会尝试一些新的飞行方向或者新的卸载比例。实际测试时也发现，如果完全不加探索噪声，模型很容易提前收敛，而且结果通常不太好。到了测试阶段，就不再添加噪声。这时候直接采用 Actor 输出动作，保证系统输出稳定策略。

3.4 本章小结

本章主要完成了无人机辅助移动边缘计算系统的整体建模，以及 DDPG 联合优化算法的设计，这部分也是全文最核心的内容。

前半部分主要围绕系统模型展开。本文采用的是单无人机、多用户的边缘计算场景。考虑到本科阶段代码实现和训练复杂度的问题，每个时间槽只让无人机服务一个用户，这样可以把资源分配问题适当简化，不然状态空间和动作空间都会变得很大，训练过程

也容易不稳定。

通信部分采用了概率型 LoS/NLoS 信道模型。无人机和地面用户之间既可能是视距链路，也可能受到建筑物等因素影响形成非视距链路。文中给出了路径损耗、信道增益以及传输速率的计算方法，这些参数后面都会直接影响任务上传时间。其实从公式也能看出来，无人机离用户越近，通信质量通常会更好，任务传输时间也会更短。

计算模型这部分采用的是部分卸载方式。也就是说，一个任务不一定全部放在本地执行，也不一定全部交给无人机处理，而是允许按比例划分。这样会比传统“全本地”或者“全卸载”更灵活一些。后面分别推导了本地计算和卸载计算对应的时延与能耗表达式。无人机能耗部分则分成飞行能耗、悬停能耗以及计算能耗三部分。因为无人机本身电池容量有限，所以能耗约束在整个系统里影响还是比较大的。

在完成系统建模之后，本文把联合优化问题进一步转化成马尔可夫决策过程。状态空间主要包含无人机位置、剩余电量以及当前任务数据量；动作空间则包括无人机位置移动和任务卸载比例。考虑到动作都是连续值，所以普通离散强化学习方法不太适合。奖励函数部分同时考虑了任务时延和无人机能耗，希望无人机在保证服务能力的同时，不至于过快耗尽电池。

算法设计部分主要采用 DDPG 算法完成联合优化。因为无人机位置移动和任务卸载比例都属于连续变量，普通离散动作强化学习方法不太适合，所以本文选择了 DDPG 作为核心算法。

文中介绍了 Actor-Critic 结构、经验回放、目标网络以及软更新等内容。Actor 网络负责根据当前状态输出动作，Critic 网络则负责评估当前动作的效果，两者在训练过程中不断相互调整。经验回放机制会把历史交互数据保存下来，再随机抽样训练，这样能够减少连续样本之间的影响，让训练过程更稳定一些。目标网络和软更新则主要用于减小训练震荡，避免网络参数变化过快。

这一章完成之后，后面的实验部分也就比较清晰。下一章会在当前模型基础上搭建仿真环境，并结合不同对比算法，对系统时延、无人机能耗以及训练收敛情况进行测试与分析。

4 仿真实验与结果分析

第四章主要对本文提出的基于 DDPG 的无人机辅助 MEC 联合优化算法进行实验验证。为了贴近动态边缘计算场景，本文搭建了对应的仿真环境，并设置多组对比实验，从训练收敛情况、系统时延、无人机能耗以及任务完成率等方面分析算法表现。本章前半部分介绍实验环境与参数配置，后续则对不同算法的实验结果进行分析与讨论。

4.1 仿真环境设置

4.1.1 开发工具与框架

本文实验采用 Python 完成实现，强化学习部分使用 PyTorch 框架搭建 DDPG 中的 Actor 网络与 Critic 网络。相比静态计算图，PyTorch 动态图在调试时更直观，改模型结构也比较方便，所以在强化学习任务里使用较多。

实验过程中，NumPy 主要用于矩阵和数值运算，Matplotlib 用于绘制训练曲线和性能对比图。整个仿真环境均在本地完成运行与调试。

4.1.2 仿真参数设置

根据第三章建立的系统模型，仿真区域设定为 $1000\text{ m} \times 1000\text{ m}$ 的正方形区域，无人机飞行高度固定为 100 m 。地面用户数量默认取 $N=5$ ，用户位置在区域内随机生成。每个时间槽长度 $\Delta t = 0.5\text{ s}$ ，无人机最大飞行速度 $v_{\max} = 20\text{ m/s}$ 。

通信相关参数：载波频率 $f_c = 2.4\text{ GHz}$ ，系统带宽 $B = 10\text{ MHz}$ ，用户发射功率 $P = 0.1\text{ W}$ ，噪声功率谱密度 $N_0 = 1 \times 10^{-17}\text{ W/Hz}$ 。LoS/NLoS 模型参数取城市环境典型值： $\eta_{\text{LoS}} = 1\text{ dB}$ ， $\eta_{\text{NLoS}} = 20\text{ dB}$ ， $a = 12.08$ ， $b = 0.15$ 。

计算相关参数：用户任务数据量 $D_i(t)$ 在 0.5 Mbit 到 2 Mbit 之间均匀随机生成，计算密 $C = 5000\text{ cycle/bit}$ 。本地 CPU 频率 $f_{\text{loc}} = 2\text{ GHz}$ ，无人机 CPU 频率 $F_{\text{UAV}} = 10\text{ GHz}$ 。

能耗相关参数：飞行能耗系数 $e_{\text{fly}} = 15\text{ J/m}$ ，悬停功率 $P_{\text{hover}} = 100\text{ W}$ ，计算能耗系数 $\epsilon = 1 \times 10^{-9}\text{ J/cycle}$ 。电池总容量 $E_{\max} = 50000\text{ J}$ ，安全电量下限 $E_{\min} = 5000\text{ J}$ 。

DDPG 算法超参数：Actor 学习率 1×10^{-4} ，Critic 学习率 1×10^{-3} ，折扣因子 $\gamma = 0.99$ ，软更新系数 $\tau = 0.001$ ，经验回放缓冲区大小 10^5 ，小批量大小 64 ，探索噪声采用 Ornstein-Uhlenbeck 过程 ($\theta = 0.15, \sigma = 0.2$)。最大训练回合数为 2000 ，设置每回合最大时间步为 100 。

这些参数主要参考了已有无人机 MEC 和强化学习相关研究中的常见设置，同时结合实际训练情况进行了适当调整，保证模型能够稳定收敛。

4.1.3 仿真流程

每个训练回合开始时，无人机初始化在区域中心位置 (500,500)，同时恢复满电状态。系统会随机生成用户任务。

在每个时间步中，DDPG 智能体根据当前状态输出动作，包括无人机位置变化以及任务卸载比例。环境执行动作后，会计算当前任务时延、无人机能耗以及对应奖励，并更新无人机位置与剩余电量。随后系统进入下一状态，同时将交互得到的经验数据存入经验回放池。

当经验池中的样本达到一定数量后，开始随机采样并更新网络参数。每轮训练结束后，记录累计奖励和平均时延等指标。训练完成后保存 Actor 网络参数，并用于后续测试阶段。

4.2 对比算法介绍

为了更直观地分析本文算法的效果，实验中设置了四种对比方法。

（1）本地计算（Local Only）

该方法不使用无人机辅助计算，所有任务全部在本地设备完成。无人机不飞行，也不参与计算。该方案主要用于观察在没有边缘卸载情况下系统的基础性能。

（2）随机卸载（Random Offloading）

该方法允许无人机参与服务，但任务卸载比例在 $[0,1][0,1][0,1]$ 范围内随机生成，并不进行学习优化。无人机按照固定顺序轮流访问用户。

这种方法虽然实现简单，但决策完全随机，容易出现信道状态较差时仍大量卸载的问题。

（3）贪婪式最短路径（Greedy Shortest Path）

无人机按照最短路径依次访问所有用户，并在每个用户位置附近悬停服务。任务卸载比例固定为 0.5。这种方式能够减少部分飞行距离，但由于卸载比例固定，无法根据实时状态动态调整策略。

（4）固定无人机 DRL（Fixed-UAV DRL）

该方法保留 DDPG 卸载策略学习，但无人机位置固定在区域中心，不进行轨迹优化。

这样可以单独观察仅优化卸载时系统性能的变化情况，同时用于分析飞行轨迹优化是否真的有必要。

上述四种方法分别对应：无无人机辅助 随机决策 固定轨迹策略 仅优化卸载能够较完整地作为本文算法的对比基准。

4.3 实验结果分析

4.3.1 训练收敛性分析

图 4.1 给出了 DDPG 训练阶段的累计奖励变化曲线。横坐标表示训练回合数，纵坐标表示累计奖励值。为了减少随机波动带来的影响，实验中对原始曲线进行了窗口大小为 80 的滑动平均处理。




图 4.1 训练过程中每回合累积奖励变化曲线

从图中可以看到，训练初期奖励值波动较大。这一阶段智能体主要依赖随机探索，动作策略不稳定，因此系统时延和能耗都比较高。随着训练进行，奖励整体开始缓慢上升，说明模型逐渐学到了更合理的飞行与卸载策略。大约在 500 回合之后，曲线变化趋于平稳，没有再出现明显震荡，说明算法基本进入收敛状态。

图 4.2 给出了训练过程中平均任务时延的变化情况。从整体趋势来看，曲线在训练初期波动比较明显。这时候智能体还处于随机探索阶段，无人机的移动方向和任务卸载比例基本没有形成稳定策略。有些时间步会出现飞了很远但通信效果并不好的情况，或者卸载比例设置不合理，所以整体时延会比较大。

随着训练不断进行，平均时延开始慢慢下降。虽然中间仍然会出现一定波动，但整体趋势已经逐渐向下。智能体一边和环境交互，一边不断修正自己的决策方式。训练大约进行到后半段之后，时延基本稳定在 0.9 s 附近。

这个时候 DDPG 已经学到了一些比较有效的调度方式。无人机不会再像初期那样频繁进行无意义移动，而是会更倾向于靠近当前任务需求较高用户区域。训练后期虽然仍然存在小范围波动，但整体已经比较稳定，没有出现大幅震荡或者持续发散的情况，说明算法具备较好的收敛性和训练稳定性，同时能够在动态环境变化下保持较为可靠的决策能力，为后续任务调度提供稳定支持。




图 4.2 训练过程中平均任务时延变化曲线

4.3.2 性能对比分析

在算法收敛后，使用测试集，同时不添加探索噪声，分别运行五种策略各 1000 个回合，记录本地计算、随机卸载、贪婪最短路径算法、固定无人机 DRL 方法和 DDPG 联合优化算法的平均时延、无人机总能耗和任务完成率，最终结果如表 4.1 所示。图 4.3、图 4.4、图 4.5 分别以柱状图形式展示对比结果。




图 4.3 不同算法平均时延对比柱状图

从图 4.3 可以看出，不同算法在任务平均时延方面存在明显差异。本地计算方案下，所有任务都由用户设备自己完成，无人机不参与服务。实验结果中平均时延为 1.25 s。用户任务规模不算特别大，本地 CPU 频率基本计算需求，不会出现特别严重的时延问题。不过这种方式只能依赖终端自身算力。一旦任务规模继续增大，或者用户设备性能下降，本地计算的压力会明显增加。

随机卸载方法虽然引入了无人机辅助，但任务卸载比例完全随机，系统并不知道什么时候适合卸载、什么时候不适合卸载。很多情况下，即使通信链路状态较差，系统仍然会强行上传任务，结果不仅传输效率低，还会增加额外开销。实验里该算法平均时延达到 0.82 s。

贪婪最短路径算法采用固定飞行路线，同时把卸载比例固定为 0.5。无人机会按照预设顺序依次靠近用户，看起来路径规划比较直接，但现实环境中用户任务量和信道质量都会不断变化，固定策略很难适应动态情况。该算法平均时延为 0.65 s。

固定无人机 DRL 方法只学习卸载比例，不调整位置。无人机始终停留在区域中心，距离边缘用户较远时，通信质量会下降。训练过程中，DDPG 逐渐学到比较保守的策略：尽量少卸载任务，更多依赖本地计算。最终系统平均时延保持在 0.58 s 左右。

相比之下，本文提出的 DDPG 联合优化算法表现更稳定。无人机会根据用户位置和任务情况动态调整飞行方向，实时修改卸载比例。无人机能够主动靠近任务需求较高的区域，通信链路质量会更好。实验结果中，本文算法平均时延稳定在 0.36 s 左右，相比随机卸载和贪婪路径方案下降很多，表现出更优的实时服务能力。




图 4.4 不同算法无人机总能耗对比柱状图

从图 4.4 可以看出，本地计算方案下，所有任务都由用户设备自己完成，无人机能耗始终为 0。随机卸载方法虽然使用了无人机参与计算，但由于卸载决策完全随机，经常在不合适的时机进行任务传输，导致通信资源利用效率较低，同时产生额外能耗。贪婪最短路径算法采用固定飞行路线和固定卸载比例，，缺乏对实际任务需求的动态适应能力。实验结果中，该算法总能耗约为 41.2 kJ，是几种方案中能耗最高的一种。固定无人机 DRL 方法实验结果显示，其无人机能耗约为 28.3 kJ。

本文提出的 DDPG 联合优化算法通过联合优化飞行轨迹和任务卸载决策，使无人机能够在保证服务质量的同时减少不必要的飞行和计算开销。实验结果表明，本文算法总能耗为 24.6 kJ，低于固定无人机 DRL 方法。从系统角度看，这部分能耗换来了更稳定的任务服务能力和更高的完成率，体现出较好的能耗控制效果。




图 4.5 不同算法任务完成率对比柱状图

从图 4.5 可以看出，各算法在任务完成率方面存在较大差异。本地计算方案下，由于所有任务均由本地设备完成，因此任务完成率达到 100%。随机卸载方法由于任务卸载比例随机选择，当通信链路条件较差时仍可能进行任务上传，容易导致任务传输失败或超时。实验结果显示，其任务完成率仅为 50%。贪婪最短路径算法无法根据环境变化动态调整策略。实验结果中，该算法任务完成率进一步下降到 35%。固定无人机 DRL 方法通过强化学习优化卸载比例，在一定程度上改善了系统性能，但由于无人机位置固定，通信链路质量仍然受到限制，因此任务完成率提升有限。

相比之下，本文提出的 DDPG 联合优化算法能够同时调整无人机飞行轨迹和任务卸载比例，无人机能够主动靠近任务需求较高的区域，保证稳定的通信质量。实验结果表明，本文算法任务完成率保持在 100%。相比随机卸载的 50%和贪婪路径的 35%，稳定性明显更好。这说明联合优化后，系统能够更合理地分配任务，不容易出现链路中断、卸载失败或者任务丢弃的问题。

表 4.1 不同算法性能对比

算法	平均时延(s)	无人机总能耗(kJ)	任务完成率
本地计算	1.25	0	100
随机卸载	0.82	32.5	50
贪婪最短路径	0.65	41.2	35
固定无人机 DRL	0.58	28.3	100
本文 DDPG	0.36	24.6	100

结合表 4.1 以及图 4.3～图 4.5 的实验结果可以发现，不同算法在时延、能耗和任务完成率之间存在明显差异。本地计算方案虽然能够保证 100%的任务完成率，并且不存在无人机能耗，但平均时延最高。随机卸载方法和贪婪最短路径算法缺乏有效的动态决策机制，任务完成率较低。固定无人机 DRL 方法利用强化学习优化卸载比例，在时延和能耗方面取得了一定改善，但位置固定，无法充分发挥无人机边缘计算优势。

相比之下，本文提出的 DDPG 联合优化算法能够根据用户位置、任务需求以及系统状态动态调整飞行轨迹和卸载比例，在平均时延、无人机能耗以及任务完成率之间取得较好的平衡。它不像随机策略那样盲目，也不像固定路径方法那样缺少灵活性。相比只优化卸载比例的方法，联合优化飞行轨迹后，无人机能够主动改善通信条件，这一点对动态场景尤其重要。因此，本文算法在整体性能和系统稳定性方面均表现出较好的优势。

4.3.3 参数影响分析

（1）任务数据量对性能的影响

将每个用户的任务数据量 D_i 分别设置为 0.5 Mbit、1.0 Mbit、1.5 Mbit、2.0 Mbit、2.5 Mbit（固定值），测试平均时延变化。结果如图 4.6 所示。




图 4.6 不同任务数据量下平均时延变化曲线

从图 4.6 可以比较直观地看到，随着任务数据量不断增加，系统平均时延也在持续上升，而且整体趋势接近线性变化。任务量较小时，系统处理压力相对较低，平均时延保持在较小范围内。当任务规模达到 2.5 Mbit 时，平均时延已经接近 0.62 s。

任务数据量变大之后，需要上传的数据会更多，本地终端和无人机侧都需要承担更大的计算压力。无论是无线传输阶段，还是后续计算阶段，处理时间都会被拉长。尤其是在带宽和计算资源固定的情况下，任务量增加后，系统整体响应时间自然会上升。

另外，图中的曲线变化相对平滑，没有出现突然陡增或者剧烈波动。这也说明当前算法在不同任务压力下仍然能够保持比较稳定的调度行为，没有因为任务规模增加而出现明显失控情况。对于无人机辅助 MEC 系统来说，这种稳定性还是比较重要的。因为真实场景中的任务到达往往并不固定，系统需要具备一定的动态适应能力。

（2）无人机算力对性能的影响

将无人机 CPU 频率 F_{UAV} 分别设为 5 GHz、10 GHz、15 GHz、20 GHz，测试平均时延变化。结果如图 4.7 所示。




图 4.7 不同无人机算力下平均时延变化曲线

从图 4.7 可以发现,随着无人机 CPU 频率逐渐提高,系统平均时延整体呈下降趋势。不过,后期变化变慢。当无人机算力从 5 GHz 提升到 10 GHz 时,平均时延从 0.48 s 下降到 0.35 s 左右。这说明在低算力阶段,无人机本身的计算能力确实会限制任务处理速度。算力提高后,卸载任务能够更快完成,所以整体时延会下降。

但当 CPU 频率继续提高到 15 GHz 甚至 20 GHz 之后,时延下降速度开始放缓,最后稳定在 0.28 s 附近。这时候可以发现,系统瓶颈已经不完全在无人机计算阶段了。

从实验现象来看,DDPG 在不同算力条件下也表现出一定自适应能力。当无人机算力较低时,算法会减少卸载比例,避免无人机处理不过来;算力提高后,系统会逐渐增加卸载任务量,更充分利用无人机资源。这说明算法并不是固定策略,而是会根据当前资源状态不断调整任务分配方式。

4.4 本章小结

本章主要围绕本文提出的 DDPG 无人机辅助 MEC 联合优化算法展开实验分析。实验部分从仿真环境搭建开始,对系统参数、训练流程以及对比算法进行了统一说明,并在后续测试中对算法性能进行了验证。

实验过程中,可以比较明显地看到 DDPG 训练曲线逐渐趋于稳定。刚开始训练时,智能体基本处于随机探索阶段,奖励值波动较大,平均任务时延也偏高。随着训练轮数增加,模型开始慢慢学会如何调整飞行位置以及任务卸载比例,系统整体开销逐渐下降。训练后期,奖励曲线基本稳定,说明算法已经能够学习到相对稳定的调度策略。整个训练过程中没有出现明显发散或者剧烈震荡,训练稳定性相对较好。

性能对比实验中，本文方法与随机卸载、贪婪最短路径、本地计算以及固定无人机 DRL 等算法进行了比较。从结果来看，随机卸载和固定路径方案在动态环境下问题比较明显。虽然这两种方法都使用了无人机，但由于缺少实时决策能力，经常会出现不合理卸载、飞行距离过长或者通信链路较差的问题，所以时延和能耗都偏高，任务完成率也比较低。

固定无人机 DRL 虽然引入了强化学习，但无人机始终停留在区域中心，没有真正参与轨迹优化。训练后系统会逐渐倾向于减少卸载任务，大部分计算还是回到本地执行。本质上，它更像一种“保守策略”，没有真正体现出无人机边缘计算的优势。

相比之下，本文 DDPG 算法会同时调整无人机位置和任务卸载比例。无人机能够主动向用户密集区域移动，在通信质量较好的情况下再进行任务卸载。这样既减少了传输时延，也降低了无效飞行带来的能耗。实验结果中，本文方法在平均时延、总能耗以及任务完成率几个指标上都保持了相对均衡的表现。虽然无人机会产生一定飞行能耗，但系统整体运行更加稳定，任务丢失情况也明显减少。

参数分析部分也能看出一些比较有意思的现象。任务数据量增大时，时延会同步增加，这一点比较符合实际情况。同时也能说明 DDPG 会根据当前负载动态调整卸载比例，而不是始终采用固定策略。

无人机算力变化实验中，即使 CPU 频率从 10 GHz 提高到 20 GHz，系统时延变化开始不明显。这个结果说明，在当前场景下，真正限制系统性能的并不完全是无人机算力，通信链路质量以及本地计算能力同样会影响整体时延。

整体来看，本章实验结果说明，采用联合优化方式后，无人机能够更灵活地完成飞行控制与任务调度。相比传统固定策略，DDPG 在动态环境下更容易适应不同任务需求，也能在时延、能耗和任务完成率之间取得相对平衡的结果。这也说明，将强化学习方法用于无人机辅助边缘计算场景是可行的。

结 论

本文主要研究的是无人机辅助移动边缘计算场景下的资源调度问题，重点放在任务卸载和无人机飞行轨迹的联合优化上。像灾害救援、临时大型活动、偏远地区通信这类场景，地面基站有时覆盖不到，甚至本身已经损坏。这时候，无人机能快速飞到目标区域上空，还能依靠较好的空地视距链路提供临时通信和计算服务，所以很适合拿来移动边缘节点。

关于无人机本身的问题。首先电池容量有限，飞一段时间电量就会下降；用户任务是动态到达的，通信信道也一直在变化。更麻烦的是，飞行路径和任务卸载其实是绑在一起的：无人机飞得近，通信速率会变好，上传时间会变短，但飞行本身又会额外耗电。传统优化方法在这种动态环境下不太容易实时求解，所以本文尝试把深度强化学习引入进来，用 DDPG 算法完成无人机轨迹和卸载比例的联合决策。

在系统建模部分，本文构建了一个单无人机、多用户的边缘计算模型。系统按时间槽运行，每个时间槽只服务一个用户，这样做虽然会牺牲一部分并行能力，但代码实现会简单很多，也更适合本科阶段完成训练与调试。通信部分采用概率型 LoS/NLoS 信道模型，分别给出了路径损耗和传输速率的计算方法。计算任务采用部分卸载模式，也就是任务既可以放在本地处理，也可以按比例卸载到无人机。文中分别推导了本地执行和卸载执行对应的时延、能耗表达式。无人机能耗部分则拆成了飞行能耗、悬停能耗以及计算能耗三部分。

后面把整个联合优化问题转成了马尔可夫决策过程。状态空间里主要包含无人机当前位置、剩余电量以及当前任务数据量；动作空间则包括无人机下一步移动方向和任务卸载比例。奖励函数同时考虑任务处理时延和无人机能耗，希望无人机既不要飞得太浪费电，也不要让任务等待太久。这样处理之后，原本比较复杂的资源调度问题，就能转化成强化学习里的连续决策问题。

算法部分采用的是 DDPG。它本身比较适合连续动作空间，像无人机位置变化、卸载比例这种连续变量都能直接输出。整个结构还是经典的 Actor-Critic 框架：Actor 负责输出动作，Critic 负责评价动作好坏。训练时加入了经验回放机制，把历史交互数据存到缓冲区里随机采样，不然连续样本相关性太强，训练容易震荡。目标网络也一起用了，通过缓慢更新参数来稳定训练过程。另外，在动作输出时加入了 OU 噪声，用来增强探

索能力。如果完全不加噪声，模型很容易在训练前期就卡在局部最优。

仿真实验部分使用 Python 和 PyTorch 完成。为了验证算法效果，文中设计了几组对比方法，包括本地计算、随机卸载、固定路径方案以及固定无人机位置的 DRL 方案。实验主要从训练收敛情况、平均时延、无人机能耗和任务完成率几个角度进行分析。训练曲线可以看到，DDPG 在前期波动比较明显，后面逐渐稳定下来，奖励值也慢慢上升。对应的平均时延则持续下降，最后收敛在较低水平。

和其他方法相比，本文算法在时延和能耗之间取得了相对更平衡的结果。固定无人机的方法虽然不需要飞行，但离部分用户较远时，上传速率会明显下降；贪婪路径方案虽然能靠近用户，但飞行距离过长，整体能耗偏高。DDPG 则会动态调整飞行方向和卸载比例，让无人机更倾向于靠近任务密集区域，同时尽量减少无意义移动。

参数实验里也能看出一些规律。任务数据量变大后，上传和计算时间也会同步增加。无人机算力提高后，时延会下降，不过下降幅度会越来越小，说明算力提升到一定程度后，系统瓶颈已经逐渐转移到通信阶段，而不是计算阶段。

本文完成了无人机辅助 MEC 场景下的联合优化建模，并利用 DDPG 实现了连续动作决策。整个方案能够让无人机根据任务情况动态调整飞行轨迹和卸载比例，在有限电量条件下尽量降低任务处理时间。后续其实还有不少可以继续扩展的地方，比如多无人机协同、更复杂的用户移动场景，或者尝试 TD3、SAC 这类更新一点的强化学习算法。如果后面能进一步结合真实硬件平台测试，结果会更接近实际应用环境。

致 谢

转眼间，我的本科生涯已经接近尾声。回首过往，我深感自己并非天赋异禀，只是凭着踏实与坚持，一步步才走到了今天。

首先衷心感谢我的导师袁晓铭老师。在整个毕设工作期间内，她始终负责地给我悉心细致的指导。同时，也感谢各位学长学姐对我论文写作的建议和指正。

感谢我的父母四年来对我的爱与无条件支持。也感谢一路同行的同学与朋友们对我无私的帮助。

四年间，我也有无数个难眠的夜晚。可是我想起来，遇到困难我对自己说的最多的话是“雄关漫道真如铁，而今迈步从头越”。有时我甚至羡慕我自己，面对困难，我总能保持平和的心态，仔细分析，然后选出最优解。

我突然想起一个月前的一件事。我偶然经过大学会馆前的那颗海棠树，发现花还没有开。可我总觉得它已经开过了。我太喜欢这棵树了，所以印象里它总是盛开或者飘落的样子。所以说，“年年岁岁花相似，岁岁年年人不同”根本不对。你只记得花儿你喜欢时的样子，可是它含苞待放时就不美了吗？

如果你是真诚地感谢花儿，就请爱它们的所有的样子吧！我很幸运能遇见你们。最后，向所有帮助过我的人，致以诚挚的谢意。

参考文献

- [1] Zeng Y, Zhang R, Lim T J. Wireless communications with unmanned aerial vehicles: Opportunities and challenges[J]. IEEE Communications Magazine, 2016, 54(5): 36-42.
- [2] Mozaffari M, Saad W, Bennis M, et al. A tutorial on UAVs for wireless networks: Applications, challenges, and open problems[J]. IEEE Communications Surveys & Tutorials, 2019, 21(3): 2334-2360.
- [3] Lyu J, Zeng Y, Zhang R, et al. Placement optimization of UAV-mounted mobile base stations[J]. IEEE Communications Letters, 2017, 21(3): 604-607.
- [4] Zeng Y, Xu J, Zhang R. Energy minimization for wireless communication with rotary-wing UAV[J]. IEEE Transactions on Wireless Communications, 2019, 18(4): 2329-2345.
- [5] Qu Y, Dai H, Wang H, et al. Service provisioning for UAV-enabled mobile edge computing[J]. IEEE Journal on Selected Areas in Communications, 2021, 39(11): 3287-3305.
- [6] Song Z, Qin X, Hao Y, et al. A comprehensive survey on aerial mobile edge computing: Challenges, state-of-the-art, and future directions[J]. Computer Communications, 2022, 191: 233-256.
- [7] Huda S M A, Moh S. Survey on computation offloading in UAV-enabled mobile edge computing[J]. Journal of Network and Computer Applications, 2022, 201: 103341.
- [8] 赵梓铭, 刘芳, 蔡志平, 等. 边缘计算: 平台、应用与挑战[J]. 计算机研究与发展, 2018, 55(2): 327-337.
- [9] 施巍松, 张星洲, 王一帆, 等. 边缘计算: 现状与展望[J]. 计算机研究与发展, 2019, 56(1): 69-89.
- [10] 刘芳正, 马博闻, 吕博枫, 等. 一种面向移动边缘计算的无人机基站部署方法[J]. 计算机科学, 2022, 49(S2): 848-854.
- [11] 王侃, 曹铁林, 李旭杰, 等. 无人机辅助边缘计算网络轨迹规划与资源分配研究综述[J]. 电子与信息学报, 2025, 47(5): 1266-1281.
- [12] 巨涛, 李林娟, 张文金, 等. 多无人机辅助的移动边缘计算任务卸载及路径优化方法[J]. 电子科技大学学报, 2025, 54(1): 72-83.
- [13] Feng C, Han Z, Yu H, et al. Computation offloading in mobile edge computing

- networks[J]. Journal of Network and Computer Applications, 2022, 202: 103366.
- [14] Liu X, Liu Y, Chen Y, et al. Multi-user computation offloading and resource allocation in mobile edge computing[J]. Sensors, 2024, 24(7): 2205.
- [15] Xu H, Fang F, Ding Z. Multiuser computation offloading for long-term energy minimization in mobile edge computing[J]. Tsinghua Science and Technology, 2023, 28(2): 315-327.
- [16] Wang Y, Fang W, Ding Y, et al. Computation offloading optimization for UAV-assisted mobile edge computing: A deep deterministic policy gradient approach[J]. Wireless Networks, 2021, 27(4): 2991-3006.
- [17] Wang L, Wang K, Pan C, et al. Deep reinforcement learning based dynamic trajectory control for UAV-assisted mobile edge computing[J]. IEEE Transactions on Mobile Computing, 2022, 21(10): 3536-3550.
- [18] Zhao N, Ye Z, Pei Y, et al. Multi-agent deep reinforcement learning for task offloading in UAV-assisted mobile edge computing[J]. IEEE Transactions on Wireless Communications, 2022, 21(9): 6949-6960.
- [19] 张海波, 荆昆仑, 刘开健, 等. 车联网中一种基于软件定义网络与移动边缘计算的卸载策略[J]. 电子与信息学报, 2020, 42(3): 645-652.
- [20] 谢万城, 李斌, 代玥玥. 空中智能反射面辅助边缘计算中基于 PPO 的任务卸载方案[J]. 计算机科学, 2022, 49(6): 3-11.
- [21] Peng P, Lin W, Wu W, et al. A survey on computation offloading in edge systems: From the perspective of deep reinforcement learning approaches[J]. Computer Science Review, 2024, 53: 100656.
- [22] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529-533.
- [23] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous control with deep reinforcement learning[EB/OL]. arXiv:1509.02971, 2015.
- [24] Fujimoto S, van Hoof H, Meger D. Addressing function approximation error in actor-critic methods[C]//Proceedings of the 35th International Conference on Machine Learning. PMLR, 2018: 1587-1596.
- [25] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[EB/OL]. arXiv:1707.06347, 2017.
- [26] Haarnoja T, Zhou A, Abbeel P, et al. Soft actor-critic: Off-policy maximum entropy

- deep reinforcement learning with a stochastic actor[C]//Proceedings of the 35th International Conference on Machine Learning. PMLR, 2018: 1861-1870.
- [27] Lowe R, Wu Y, Tamar A, et al. Multi-agent actor-critic for mixed cooperative-competitive environments[C]//Advances in Neural Information Processing Systems 30. 2017.
- [28] Peng P, Lin W, Wu W, et al. A survey on computation offloading in edge systems: From the perspective of deep reinforcement learning approaches[J]. Computer Science Review, 2024, 53: 100656.
- [29] Hortelano D, de Miguel I, Durán R J, et al. A comprehensive survey on reinforcement-learning-based computation offloading techniques in edge computing systems[J]. Journal of Network and Computer Applications, 2023, 216: 103669.
- [30] Gronauer S, Diepold K. Multi-agent deep reinforcement learning: A survey[J]. Artificial Intelligence Review, 2022, 55(2): 895-943.
- [31] Luo Z, Zhao C, Min G, et al. Reinforcement learning-based computation offloading in mobile edge computing: A survey[J]. Alexandria Engineering Journal, 2024, 95: 84-102.
- [32] Ismail A A, Abualigah L, Diabat A, et al. A survey on resource scheduling approaches in multi-access edge computing based on deep reinforcement learning[J]. Cluster Computing, 2025, 28: 1-35.

附 录

附录 A

WIRELESS NETWORKING WITH UAVS: MOTIVATING APPLICATION USE CASES

In order to paint a clear picture on how UAVs can indeed be used as flying wireless base stations, in this section, we overview a number of prospective applications for such a wireless-centric UAV deployment. The applications are drawn from a variety of scenarios, that include imminent use cases, such as for public safety scenarios or hotspot coverage, as well as more "futuristic" applications such as the use of UAVs as caching apparatus or IoT enablers. Naturally, in all such applications, the UEs of the system can include cellular connected UAV-UEs which we will also discuss. Note that this section restricts its attention to the application scenarios, while the challenges are left for a deeper treatment in Section III.

Here, we discuss the key applications of UAV-mounted aerial base stations in 5G.

1) Coverage and Capacity Enhancement of Beyond 5G Wireless Cellular Networks: The need for high-speed wireless access has been incessantly growing, fueled by the rapid proliferation of highly capable mobile devices such as smartphones, tablets, and more recently drone-UEs and IoT-style gadgets. As such, the capacity and coverage of existing wireless cellular networks have been extensively strained, which led to the emergence of a plethora of wireless technologies that seek to overcome this challenge. Such technologies, which include device-to-device (D2D) communications, ultra dense small cell networks, and millimeter wave (mmW) communications, are collectively viewed as the nexus of next-generation 5G cellular systems. However, despite their invaluable benefits, those solutions have limitations of their own. For instance, D2D communication will undoubtedly require better frequency planning and resource usage in cellular networks. Meanwhile, ultra dense small cell networks face many challenges in terms of backhaul, interference, and overall network modeling. Similarly, mmW communication is limited by blockage and high reliance on LoS communication to effectively deliver the promise of high-speed, low latency communications. These challenges will be further exacerbated in UAV-UEs scenarios.

We envision UAV-carried flying base stations as an inevitable complement for such a heterogeneous 5G environment, which will allow overcoming some of the challenges of the

existing technologies. Deploying LAP-UAVs can be a cost effective approach for providing wireless connectivity to geographical areas with limited cellular infrastructure. Moreover, the use of UAV base stations becomes promising when deploying small cells for the sole purpose of servicing temporary events (e.g., sport events and festivals), is not economically viable, given the short period of time during which these events require wireless access. Meanwhile, HAP-UAVs can provide a more long-term sustainable solution for coverage in such rural environments. Mobile UAVs can provide on-demand connectivity, high data rate wireless service, and traffic offloading opportunity in hotspots and during temporary events such as football games or Presidential inaugurations. In this regard, AT&T and Verizon have already announced several plans to use flying drones to provide temporarily boosted Internet coverage for college football national championship and Super Bowl. Clearly, flying base stations can provide an important complement to ultra dense small cell networks.

In addition, UAV-enabled mmW communications is a promising application of UAVs that can establish LoS communication links to users. This, in turn, can be an attractive solution to provide high capacity wireless transmission, while leveraging the advantages of both UAVs and mmW links. Moreover, combining UAVs with mmW and potentially massive multiple input multiple output (MIMO) techniques can create a whole new sort of dynamic, flying cellular network for providing high capacity wireless services, if well planned and operated. UAVs can also assist various terrestrial networks such as D2D and vehicular networks. For instance, owing to their mobility and LoS communications, drones can facilitate rapid information dissemination among ground devices. Furthermore, drones can potentially improve the reliability of wireless links in D2D and vehicle-to-vehicle (V2V) communications while exploiting transmit diversity. In particular, flying drones can help in broadcasting common information to ground devices thus reducing the interference in ground networks by decreasing the number of transmissions between devices. Moreover, UAV base stations can use air-to-air links to service other cellular-connected UAV-UEs, to alleviate the load on the terrestrial network.

For the aforementioned cellular networking scenarios, it is clear that the use of UAVs is quite natural due to their key features given in Tables III and IV such as agility, mobility, flexibility, and adaptive altitude. In fact, by exploiting these unique features as well as establishing LoS communication links, UAVs can boost the performance of existing ground wireless networks in terms of coverage, capacity, delay, and overall quality-of-service. Such

scenarios are clearly promising and one can see UAVs as being an integral part of beyond 5G cellular networks, as the technology matures further, and new operational scenarios emerge. Naturally, reaping these benefits will require overcoming numerous challenges, that we outline in Section III.

2) UAVs as Flying Base Stations for Public Safety Scenarios: Natural disasters such as floods, hurricanes, tornados, and severe snow storms often yield devastating consequences in many countries. During wide-scale natural disasters and unexpected events, the existing terrestrial communication networks can be damaged or even completely destroyed, thus becoming significantly overloaded, as evidenced by the recent aftermath of Hurricanes Sandy and Irma. In particular, cellular base stations and ground communications infrastructure can be often compromised during natural disasters. In such scenarios, there is a vital need for public safety communications between first responders and victims for search and rescue operations. Consequently, a robust, fast, and capable emergency communication system is needed to enable effective communications during public safety operations. In public safety scenarios, such a reliable communication system will not only contribute to improving connectivity, but also to saving lives.

In this regard, FirstNet in the United States was established to create a nationwide and high-speed broadband wireless network for public safety communications. The potential broadband wireless technologies for public safety scenarios include 4G long term evolution (LTE), WiFi, satellite communications, and dedicated public safety systems such as TETRA and APCO25. However, these technologies may not provide flexibility, low-latency services, and swift adaptation to the environment during natural disasters. In this regard, the use of UAV-based aerial networks is a promising solution to enable fast, flexible, and reliable wireless communications in public safety scenarios. Since UAVs do not require highly constrained and expensive infrastructure (e.g., cables), they can easily fly and dynamically change their positions to provide on-demand communications to ground users in emergency situations. In fact, due the unique features of UAVs such as mobility, flexible deployment, and rapid reconfiguration, they can effectively establish on-demand public safety communication networks. For instance, UAVs can be deployed as mobile aerial base stations in order to deliver broadband connectivity to areas with damaged terrestrial wireless infrastructure. Moreover, flying UAVs can continuously move to provide full coverage to a given area within a minimum possible time. Therefore, the use of UAV mounted base stations

can be an appropriate solution for providing fast and ubiquitous connectivity in public safety scenarios.

3) UAV-assisted Terrestrial Networks for Information Dissemination: With their mobility and LoS opportunities, UAVs can support terrestrial networks for information dissemination and connectivity enhancement. For instance, as shown in Figure 3, UAVs can be used as flying base stations to assist a D2D network or a mobile ad-hoc network in information dissemination among ground devices. While D2D networks can provide an effective solution for offloading cellular data traffic and improving network capacity and coverage, their performance is limited due to the short communication range of devices as well as potentially increasing interference. In this case, flying UAVs can facilitate rapid information dissemination by intelligently broadcasting common files among ground devices. For example, UAV-assisted D2D networks allow the rapid spread of emergency or evacuation messages in public safety situations. Likewise, drones can play a key role in vehicular networks (i.e., V2V communications) by spreading safety information across the vehicles. Drones can also enhance reliability and connectivity of D2D and V2V communication links. On the one hand, using drones can mitigate interference by reducing the number of required transmission links between ground devices. On the other hand, mobile drones can introduce transmit diversity opportunities thus boosting reliability and connectivity in D2D, ad-hoc, and V2V networks. One effective approach for employing such UAV-assisted terrestrial networks is to leverage clustering of ground users. Then, a UAV can directly communicate with the head of the clusters and the multi-hop communications are performed inside the clusters. In this case, the connectivity of terrestrial networks can be significantly improved by adopting efficient clustering approaches and exploiting UAVs' mobility.

4) 3D MIMO and Millimeter Wave Communications: Due to their aerial positions and their ability to deploy on demand at specific locations, UAVs can be viewed as flying antenna systems that can be exploited for performing massive MIMO, 3D network MIMO, and mmW communications. For instance, in recent years, there has been considerable interest in the use of 3D MIMO, also known as full dimension MIMO, by exploiting both the vertical and horizontal dimensions in terrestrial cellular networks. In particular, as shown in Figure 4, 3D beamforming enables the creation of separate beams in the three-dimensional space at the same time, thus reducing inter-cell interference. Compared to the conventional two-dimensional MIMO, 3D MIMO solutions can yield higher overall system throughput and

can support a higher number of users. In general, 3D MIMO is more suitable for scenarios in which the number of users is high and they are distributed in three dimensions with different elevation angles with respect to their serving base station. Due to the high altitude of UAV-carried flying base stations, ground users can be easily distinguishable at different altitudes and elevation angles measured with respect to the UAV. Furthermore, LoS channel conditions in UAV-to-ground communications enable effective beamforming in both azimuth and elevation domains (i.e., in 3D). Therefore, UAV-BSs are suitable candidates for employing 3D MIMO.

Furthermore, the use of a drone-based wireless antenna array provides a unique opportunity for airborne beamforming. A drone antenna array whose elements are single-antenna drones can provide MIMO and beamforming opportunities to effectively service ground users in downlink and uplink scenarios. Compared to conventional antenna array systems, a drone-based antenna array has the following advantages: 1) The number of antenna elements (i.e., drones) is not limited by space constraints, 2) Beamforming gains can be increased by dynamically adjusting the array element spacing, and 3) The mobility and flexibility of drones allow effective mechanical beam-steering in any 3D direction. In addition, the use of a large number of small UAVs within an array formation can provide unique massive MIMO opportunities. Such UAV-based massive antenna array can form any arbitrary shape and effectively perform beamforming.

UAVs can also be a key enabler for mmW communications. On the one hand, UAVs equipped with mmW capabilities can establish LoS connections to ground users thus reducing propagation loss while operating at high frequencies. On the other hand, with the use of small-size antennas (at mmW frequencies) on UAVs, one can exploit advanced MIMO techniques such as massive MIMO in order to operate mmW communications. Meanwhile, swarms of UAVs can create reconfigurable antenna arrays in the sky.

5) UAVs for IoT Communications: Wireless networking technologies are rapidly evolving into a massive IoT environment that must integrate a heterogeneous mix of devices ranging from conventional smartphones and tablets to vehicles, sensors, wearables, and naturally, drones. Realizing the much coveted applications of the IoT such as smart cities infrastructure management, healthcare, transportation, and energy management requires effective wireless connectivity among a massive number of IoT devices that must reliably deliver their data, typically at high data rates or ultra low latency. The massive nature of the

IoT requires a major rethinking to the way in which conventional wireless networks (e.g., cellular systems) operate.

For instance, in an IoT environment, energy efficiency, ultra low latency, reliability, and high-speed uplink communications become major challenges that are not typically as critical in conventional cellular network use cases. In particular, IoT devices are highly battery limited and are typically unable to transmit over a long distance due to their energy constraints. For instance, in areas which experience an intermittent or poor coverage by terrestrial wireless networks, battery-limited IoT devices may not be able to transmit their data to distant base stations due to their power constraints. Furthermore, due to the various applications of IoT devices, they might be deployed in environments with no terrestrial wireless infrastructure such as mountains and desert areas.

中文译文 A

利用无人机的无线网络技术：激发应用案例的开发

为了清晰地展示无人机如何能够真正地作为飞行无线基站被使用，本节将概述此类以无线通信为中心的无人机部署的若干潜在应用。这些应用来自各种不同的场景，包括即将出现的用例，例如用于公共安全场景或热点覆盖，以及更“未来主义”的应用，例如将无人机用作缓存设备或物联网的启用工具。当然，在所有这些应用中，系统的用户设备（UE）可以包括我们也将讨论的蜂窝连接无人机-UE。请注意，本节仅关注应用场景，而挑战则留到第 III 节进行更深入的探讨。

在此，我们讨论了安装在无人机上的空中基站在 5G 中的关键应用。

超越 5G 无线蜂窝网络的覆盖和容量增强：对高速无线接入的需求一直在不断增长，这是由诸如智能手机、平板电脑以及最近的无人机-UE 和物联网式设备等高性能移动设备的迅速普及所推动的。因此，现有的无线蜂窝网络的容量和覆盖范围已严重受限，这促使众多旨在解决这一难题的无线技术应运而生。这些技术包括设备到设备（D2D）通信、超密集小型蜂窝网络以及毫米波（mmW）通信，它们共同被视为下一代 5G 蜂窝系统的核心。然而，尽管这些解决方案具有诸多显著优势，但它们自身也存在局限性。例如，D2D 通信无疑将需要在蜂窝网络中进行更优的频率规划和资源利用。同时，超密集小型蜂窝网络在回程、干扰以及整体网络建模方面面临诸多挑战。同样，毫米波通

信受到遮挡的影响，并且高度依赖视距通信才能有效实现高速、低延迟通信的承诺。在无人机-用户设备（UAV-UE）场景中，这些挑战将会进一步加剧。我们设想，搭载无人机的空中基站将成为这种多样化的 5G 环境的必然补充，这将有助于克服现有技术的一些难题。部署 LAP-UAV（无人机接入点）可以作为一种经济有效的方案，为基础设施有限的地理区域提供无线连接服务。此外，当为了服务临时活动（例如体育赛事和节日）而仅部署小型基站时，使用无人机基站具有很大的前景，因为这些活动所需的无线接入时间很短，而这种经济上的可行性并不高。与此同时，HAP-UAV（高空接入点无人机）可以为这类偏远地区提供更长期可持续的覆盖解决方案。移动无人机可以在热点区域和临时活动（如足球比赛或总统就职典礼）期间提供按需连接、高速数据无线服务和流量卸载机会。在这方面，美国电话电报公司（AT&T）和威瑞森（Verizon）已经宣布了几项计划，即利用飞行无人机为大学橄榄球全国锦标赛和超级碗提供临时增强的互联网覆盖。显然，飞行基站能够为超密集小型基站网络提供重要的补充。

此外，利用无人机实现毫米波通信是一种极具前景的无人机应用，它能够为用户提供直达链路的通信服务。这样一来，这便能成为一种极具吸引力的解决方案，能够提供高容量的无线传输服务，同时充分利用无人机和毫米波链路的优势。此外，将无人机与毫米波以及可能的大量输入大量输出（MIMO）技术相结合，如果规划和运营得当，可以创建一种全新的动态飞行蜂窝网络，用于提供高容量的无线服务。无人机还可以协助各种地面网络，例如设备到设备（D2D）网络和车辆网络。例如，由于其移动性和直达链路通信的特点，无人机可以促进地面设备之间的快速信息传播。此外，无人机有可能通过利用发射分集来提高设备到设备和车辆到车辆（V2V）通信中的无线链路可靠性。特别是，飞行中的无人机可以帮助向地面设备广播通用信息，从而通过减少设备之间的传输次数来降低地面网络中的干扰。此外，无人机基站还可以通过空对空链路为其他蜂窝连接的无人机用户设备提供服务，以减轻地面网络的负载。

对于上述的蜂窝网络场景，很明显，由于无人机所具有的表三和表四中所列的关键特性（如灵活性、移动性、可变性以及自适应高度），使用无人机是相当自然的。实际上，通过利用这些独特的特性并建立视距通信链路，无人机可以提高现有地面无线网络在覆盖范围、容量、延迟和整体服务质量方面的性能。此类场景显然是很有前景的，并且随着技术的进一步成熟以及新的操作场景的出现，可以将无人机视为超越 5G 蜂窝网络的一个组成部分。自然地，要获得这些好处就需要克服众多挑战，我们在第三部分中

对此进行了概述。

2) 无人机作为公共安全场景的空中基站：诸如洪水、飓风、龙卷风和严重雪灾等自然灾害在许多国家往往会造成毁灭性的后果。在大规模自然灾害和突发事件发生时，现有的地面通信网络可能会遭到破坏甚至完全毁坏，从而变得不堪重负，这一点从最近飓风“桑迪”和“艾尔玛”的灾后情况中就可见一斑。特别是在自然灾害发生时，蜂窝基站和地面通信基础设施往往会受到损害。在这种情况下，首先响应者与受灾者之间进行公共安全通信的需求变得极为迫切，以用于搜索和救援行动。因此，需要一个强大、快速且可靠的应急通信系统，以便在公共安全行动中实现有效的通信。在公共安全场景中，这样一个可靠的通信系统不仅能改善连接性，还能拯救生命。

在这方面，美国的“第一网络”项目就是为了创建一个覆盖全国、高速的宽带无线网络而设立的，用于公共安全通信。适用于公共安全场景的潜在宽带无线技术包括 4G 长期演进（LTE）、WiFi、卫星通信以及诸如 TETRA 和 APCO25 等专用公共安全系统。然而，这些技术可能无法提供灵活性、低延迟服务以及在自然灾害期间对环境的快速适应能力。在这方面，利用基于无人机的空中网络是一个很有前景的解决方案，能够使公共安全场景中的无线通信实现快速、灵活和可靠。由于无人机不需要高度受限且昂贵的基础设施（例如电缆），它们可以轻松飞行并动态改变位置，以便在紧急情况下为地面用户提供按需通信服务。事实上，由于无人机的独特特性，如移动性、灵活部署和快速重新配置，它们能够有效地建立按需的公共安全通信网络。例如，无人机可以作为移动的空中基站部署，以向具有受损地面无线基础设施的区域提供宽带连接。此外，飞行中的无人机可以持续移动，以在尽可能短的时间内为给定区域提供全面覆盖。因此，使用安装有基站的无人机可以成为在公共安全场景中提供快速和无处不在的连接的适当解决方案。

3) 无人机辅助的地面网络用于信息传播：凭借其移动性和视距传播机会，无人机能够为地面网络提供信息传播和连接增强的支持。例如，如图 3 所示，无人机可以作为飞行基站来协助 D2D 网络或移动自组织网络在地面设备之间进行信息传播。虽然 D2D 网络能够为移动数据流量卸载提供有效解决方案，并提高网络容量和覆盖范围，但由于设备的通信范围较短以及可能增加的干扰，其性能受到限制。在这种情况下，飞行中的无人机可以通过在地面设备之间智能广播常见文件来促进快速信息传播。例如，无人机辅助的 D2D 网络能够在公共安全情况下迅速传播紧急或疏散消息。同样，无人

机在车辆网络（即 V2V 通信）中也能发挥关键作用，通过在车辆之间传播安全信息。无人机还可以增强 D2D 和 V2V 通信链路的可靠性和连接性。一方面，使用无人机可以减少地面设备之间所需的传输链路数量，从而减轻干扰。另一方面，移动无人机能够引入传输分集的机会，从而提高 D2D、自组织网络和 V2V 网络的可靠性与连接性。采用此类无人机辅助的地面网络的一种有效方法是利用地面用户的聚类。然后，一架无人机可以直接与集群的头节点进行通信，而多跳通信则在集群内部进行。在这种情况下，通过采用高效的聚类方法并利用无人机的移动性，地面网络的连接性可以得到显著改善。

4) 3D MIMO 和毫米波通信：由于其飞行位置以及能够根据特定位置需求进行部署的能力，无人机可以被视为可利用的飞行天线系统，可用于执行大规模 MIMO、3D 网络 MIMO 和毫米波通信。例如，近年来，人们对利用 3D MIMO（也称为全维度 MIMO）产生了极大的兴趣，通过利用地面蜂窝网络中的垂直和水平维度来实现。特别是，如图 4 所示，3D 波束成形能够同时在三维空间中创建多个独立的波束，从而减少相邻小区之间的干扰。与传统的二维 MIMO 方案相比，3D MIMO 解决方案能够实现更高的整体系统吞吐量，并且能够支持更多的用户。总的来说，3D MIMO 更适合用户数量众多且分布在三维空间中、相对于其服务基站具有不同仰角的用户场景。由于搭载在无人机上的移动基站的高度较高，因此相对于无人机测量的不同高度和仰角，地面用户能够很容易地区分。此外，无人机与地面通信中的视距信道条件能够在方位和仰角两个领域（即在三维空间中）实现有效的波束成形。因此，搭载无人机的基站非常适合采用 3D MIMO 技术。

此外，使用基于无人机的无线天线阵列为空中波束成形提供了一个独特的机会。一种由单个天线无人机组成的无人机天线阵列能够在下行和上行场景中为地面用户提供 MIMO 和波束成形服务的机会。与传统的天线阵列系统相比，基于无人机的天线阵列具有以下优势：1) 天线单元（即无人机）的数量不受空间限制的约束，2) 通过动态调整阵列单元间距可以增加波束成形增益，3) 无人机的移动性和灵活性允许在任何三维方向上进行有效的机械波束控制。此外，在阵列形成中使用大量小型无人机可以提供独特的大规模 MIMO 机会。这种基于无人机的大规模天线阵列可以形成任何任意形状，并有效地执行波束成形。

无人机也可以成为毫米波通信的关键推动者。一方面，配备毫米波能力的无人机可以与地面用户建立视距连接，从而在高频段运行时减少传播损耗。另一方面，通过在无

人机上使用小型天线（在毫米波频率下），人们可以利用先进的多输入多输出技术，如大规模多输入多输出技术，来实现毫米波通信。同时，成群的无人机能够在空中形成可重新配置的天线阵列。

5) 用于物联网通信的无人机：无线网络技术正迅速发展成为一个庞大的物联网环境，该环境必须整合各种类型的设备，从传统的智能手机和平板电脑到车辆、传感器、可穿戴设备，当然还有无人机。要实现物联网所期望的诸多应用，例如智能城市基础设施管理、医疗保健、交通运输和能源管理，就需要在大量物联网设备之间实现有效的无线连接，这些设备必须能够可靠地传输数据，通常是在高速率或超低延迟的情况下。物联网的规模特性要求对传统无线网络（例如蜂窝系统）的运作方式进行重大重新思考。

例如，在物联网环境中，能源效率、超低延迟、可靠性和高速上行通信成为主要挑战，而在传统的蜂窝网络使用场景中，这些通常并非那么关键。特别是，物联网设备的电池续航能力很强，而且由于其能量限制，通常无法进行长距离传输。例如，在那些地面无线网络覆盖不稳定或信号质量不佳的地区，电池容量有限的物联网设备可能会因电力限制而无法将数据传输至远处的基站。此外，由于物联网设备的应用多种多样，它们可能会被部署在没有地面无线基础设施的环境中，比如山区和沙漠地区。